



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده ریاضی و علوم کامپیوتر

پروژه کارشناسی
علوم کامپیوتر

یادگیری تقویتی ایمن با تنظیم نیروی اپراتور در اسکن
رباتیک اولتراسوند ستون فقرات

**HAS-RL: Human-Adaptive Safe Reinforcement
Learning for**

**Clinician-Configured Force Safety in Robotic
Ultrasound Spinal Scanning**

نگارش
محمدهادی نیکنام

استاد راهنما
دکتر روح الله احمدیان

داور
دکتر مهدی قطعی

تابستان ۱۴۰۵

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

صفحه فرم ارزیابی و تصویب پایان نامه - فرم تأیید اعضاء کمیته دفاع

در این صفحه فرم دفاع یا تأیید و تصویب پایان نامه موسوم به فرم کمیته دفاع - موجود در پرونده آموزشی - را قرار دهید.

نکات مهم:

- نگارش پایان نامه/رساله باید به **زبان فارسی** و بر اساس آخرین نسخه دستورالعمل و راهنمای تدوین پایان نامه های دانشگاه صنعتی امیرکبیر باشد.(دستورالعمل و راهنمای حاضر)
- رنگ جلد پایان نامه/رساله چاپی کارشناسی، کارشناسی ارشد و دکترا باید به ترتیب مشکی، طوسی و سفید رنگ باشد.
- چاپ و صحافی پایان نامه/رساله بصورت **پشت و رو(دورو)** بلامانع است و انجام آن توصیه می شود.



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

به نام خدا

تعهدنامه اصالت اثر

تاریخ: تابستان ۱۴۰۵

اینجانب **محمدهادی نیکنام** متعهد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی اساتید دانشگاه صنعتی امیرکبیر بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مآخذ ذکر گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است. در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی امیرکبیر می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی امیرکبیر ممنوع است. نقل مطالب با ذکر مآخذ بلامانع است.

محمدهادی نیکنام

امضا

تقدیم بہ:

پدر و مادر عزیزم،

بہ پاس سال ہامہربی دریغ، فداکاری، بردباری و حمایت ہای ہمیشگی شان...

سپاسگزاری

بر خود لازم می‌دانم مراتب قدردانی و سپاس صمیمانه خود را از استاد ارجمند و راهنمای گرامی‌ام، **جناب آقای دکتر روح‌الله احمدیان** ابراز نمایم که با راهنمایی‌های دلسوزانه، بینش علمی عمیق و رهنمودهای ارزشمندشان، همواره پشتیبان و راهگشای من در طول انجام این پژوهش بوده‌اند. همچنین از داور محترم، **جناب آقای دکتر مهدی قطعی** به پاس دقت نظر، راهنمایی‌ها و نظرات سازنده‌شان صمیمانه سپاسگزاری می‌کنم.

در پایان، مراتب امتنان و قدردانی بی‌کران خود را نثار پدر و مادر عزیزم می‌نمایم که آرامش، محبت، بردباری و حمایت‌های بی‌دریغ‌شان ارزشمندترین سرمایه زندگی من بوده و این دستاورد بی‌شک ثمره مهر و دعای خیر آنان است.

مهدی کیانم

تابستان ۱۴۰۵

چکیده

تصویربرداری اولتراسوند رباتیک راهکاری نویدبخش برای استانداردسازی اسکن‌های تشخیصی و کاهش خستگی سونوگرافر است؛ با این حال، سامانه‌های رباتیک کمکی به دلیل تماس فیزیکی مستقیم با بدن بیمار، ملزم به رعایت قیود سخت‌گیرانه برای فشار ایمن هستند؛ مقداری که بسته به نوع بافت، شرایط بالینی و ترجیح پزشک تغییر می‌کند. روش‌های پیشین یادگیری تقویتی ایمن در اولتراسوند رباتیک، یک policy را بر اساس یک آستانه نیروی ثابت آموزش می‌دهند؛ از این رو با هر تغییر در حد مجاز، کل فرایند آموزش باید از ابتدا تکرار شود. از سوی دیگر، روش‌های متأخر تنظیم متغیر دوگان مبتنی بر الگوریتم‌های باندیتی، صرفاً برای محیط‌های آفلاین ارائه شده‌اند و انتقال مستقیم آن‌ها به حلقه گرادیان policy آنلاین، ناپایداری شدیدی در فرایند یادگیری ایجاد می‌کند. در این پایان‌نامه، چارچوب HAS-RL با چهار نوآوری اصلی معرفی می‌شود: الف) تنظیم آنلاین فشار ایمنی به صورت زیروشات: سقف مجاز تعیین شده توسط اپراتور مستقیماً به عنوان ورودی آنلاین در بردار مشاهده قرار گرفته و یک policy واحد روی یک برنامه یادگیری مرحله‌ای آموزش می‌بیند؛ این مدل در زمان استقرار بدون نیاز به بازآموزی، تغییر آنلاین حد فشار در حین اسکن را بدون نقض قید دنبال می‌کند؛ ب) سازوکار لاگرانژ باندیتی هموار شده SBL که متغیر دوگان باندیتی را با میانگین متحرک نمایی از امید ریاضی متغیر دوگان هموار ساخته و به بالاترین میانگین کیفیت تصویر ($60.3/0$) و همگرایی کاملاً پایدار دست می‌یابد؛ ج) بهبود رهگیری مسیر با اضافه کردن خطای پیش‌بین به state که مقدار RMSE رهگیری را ۲۸ درصد کاهش می‌دهد؛ د) ایمنی پنجره آکوستیک دوطرفه که قید فشار را به جای سقفی یک‌طرفه، به صورت یک پنجره بالینی $[\kappa_{low}, \kappa_{high}]$ مدل کرده و از ظرفیت کامل بازه تماس جهت بهبود تصویربرداری بهره‌برداری می‌نماید. کلیه آزمایش‌ها در یک شبیه‌ساز سبک پیاده‌سازی شده و روی پردازنده مرکزی کاملاً بازتولیدپذیر هستند.

واژه‌های کلیدی:

یادگیری تقویتی ایمن، اولتراسوند رباتیک، فرایند تصمیم‌گیری مارکوف مقید، تنظیم لاگرانژ، ایمنی زیروشات، ایمنی تعامل انسان و ربات

فهرست مطالب

عنوان

صفحه

۱	مقدمه و کلیات پژوهش	۲
۱-۱	مقدمه و انگیزه پژوهش	۳
۲-۱	بررسی شکاف‌های پژوهشی در مطالعات پیشین	۳
۳-۱	نوآوری‌ها و دستاوردهای پژوهش	۴
۴-۱	محدوده و شفافیت علمی دستاوردها	۵
۵-۱	ساختار پایان‌نامه	۶
۲	پیشینه پژوهش و مبانی نظری	۷
۱-۲	مروری بر پیشینه پژوهش	۸
۱-۱-۲	یادگیری تقویتی ایمن و CMDP	۸
۲-۱-۲	تثبیت و کنترل نوسانات متغیر دوگان لاگرانژ	۸
۳-۱-۲	متغیرهای دوگان باندیتی و یادگیری تقویتی آفلاین	۹
۴-۱-۲	تصویربرداری اولتراسوند رباتیک کمکی و یادگیری تقویتی ایمن (Robot-Assisted Ultrasound)	۹
۲-۲	مبانی نظری و صورت‌بندی ریاضی	۱۰
۱-۲-۲	فرایند تصمیم‌گیری مارکوف مقید (CMDP)	۱۰
۲-۲-۲	الگوریتم PPO با دو کریتیک و برآورد مزیت تصمیم‌یافته (GAE)	۱۰
۳-۲-۲	آزادسازی لاگرانژ و ادونتیج ترکیبی ایمن	۱۱
۳	شبیه‌ساز اولتراسوند HAS-RL	۱۳
۱-۳	انگیزه توسعه و محدودیت‌های محیط‌های پیشین	۱۴
۲-۳	سینماتیک حرکت و کنترل امپدانس نیرو	۱۴
۳-۳	مدل تحلیلی کیفیت تصویر و رندرینگ حالت B	۱۵
۴-۳	صورت‌بندی تابع پاداش ترکیبی و هزینه ایمنی	۱۶
۵-۳	بردار مشاهده: سقف ایمنی و پیش‌نگری آینده	۱۷
۴	چارچوب پیشنهادی HAS-RL	۱۸

۱۹	تنظیم آنلاین فشار ایمنی به صورت زیروشات
۱۹	۲-۴ سازوکار لاگرانژ باندیتی هموار شده (SBL)
۱۹	۱-۲-۴ به روزرسانی وزن های باندیت
۲۰	۲-۲-۴ روش های مقایسه ای در تحلیل ابلیشن
۲۱	۳-۴ رهگیری پیش بینانه خطا
۲۲	۴-۴ گذار از سقف منفرد به پنجره تشخیصی دوطرفه
۲۳	۱-۴-۴ تمایز ساختاری دو نسخه سازوکار SBL
۲۴	۵ ارزیابی تجربی، نتایج و بحث
۲۵	۱-۵ تنظیمات و پیکربندی آزمایش ها
۲۶	۲-۵ مقایسه سیاست های HAS-RL با بیس لاین بدون قید
۲۷	۳-۵ ارزیابی ایمنی زیروشات با سقف متغیر اپراتور
۲۸	۴-۵ تحلیل ابلیشن الف: اثر پیش نگر بر رهگیری جانبی
۲۹	۵-۵ تحلیل ابلیشن ب: ارزیابی روش های متغیر دوگان در نسخه تک طرفه (سقفی) SBL
۳۰	۶-۵ پنجره دوطرفه اپراتور: بهره گیری کامل از دامنه مجاز نیرو
۳۲	۷-۵ تحلیل ابلیشن ج: ارزیابی روش های متغیر دوگان در نسخه دوطرفه (پنجره ای) SBL
۳۳	۸-۵ بحث و بررسی
۳۴	۹-۵ محدودیت های پژوهش
۳۴	۱۰-۵ نتیجه گیری و افق های آینده
۳۶	منابع و مراجع
۳۸	پیوست: جدول فرامترها و مشخصات پیاده سازی
۴۰	واژه نامه ی فارسی به انگلیسی
۴۳	واژه نامه ی انگلیسی به فارسی

فهرست اشکال

صفحه

شکل

- ۱-۱ انطباق زیروشات policy چارچوب HAS-RL با تغییر آنلاین حد فشار در حین اسکن (۱۱ → ۴ → ۹ نیوتن). خطچین قرمز سقف ایمنی فعال و منحنی آبی پاسخ دینامیکی policy را بدون نقض قید نشان می‌دهد. ۶
- ۱-۳ نمونه فریم‌های دوبعدی حالت B-mode تولیدشده توسط محیط شبیه‌ساز سونوگرافی (نمایش در هر ۱۰ گام پویش). این تصویر نحوه عملکرد محیط سونوگرافی را نشان می‌دهد که در آن اثرات فیزیکی امواج اولتراسوند نظیر نویز اسپکل، بازتاب پرنعکاس کمان استخوانی ستون فقرات، و سایه آکوستیک پشت مهره بر مبنای موقعیت و وضعیت تماس پروب به صورت پیوسته رندر می‌گردند. ۱۶
- ۱-۵ مقایسه هم‌زمان رفتار نسخه تک‌طرفه HAS-RL با بیس‌لاین بدون قید در سقف $\kappa = 5$ نیوتن. بالا-چپ: نیروی تماس در برابر سقف؛ بیس‌لاین (قرمز) پیوسته بالاتر از سقف حرکت می‌کند و روش پیشنهادی (سبز) زیر سقف باقی می‌ماند. بالا-راست: نقض‌های تجمعی (بیس‌لاین به ۹۶ می‌رسد و روش ما در صفر است). پایین-چپ: رد کیفیت تصویر. پایین-راست: رهگیری دقیق انحنای ستون فقرات. ۲۷
- ۲-۵ رفتار ایمنی زیروشات policy واحد. policy بدون بازآموزی نیروی تماس را با κ تطبیق داده و هرگز از سقف فعال عبور نمی‌کند. ۲۸
- ۳-۵ پایداری متغیر دوگان در طول آموزش (بذر صفر). چپ: تغییرات ضریب فعال ۸؛ باندیت خام (قرمز) میان بازوها دچار جهش‌های شدید است، صعود دوگان (آبی) بسیار کند بالا می‌رود و روش پیشنهادی SBL (سبز) روندی کاملاً نرم دارد. راست: نوسانات نقض‌های هر دوره. ۳۰
- ۴-۵ رفتار policy در پنجره‌های دوطرفه مختلف اپراتور. نوار خاکستری پنجره مجاز $[\kappa_{\text{low}}, \kappa_{\text{high}}]$ و منحنی سبز نیروی تماس اعمالی را نشان می‌دهد که کاملاً درون بازه حرکت می‌کند. ۳۱

فهرست جداول

صفحه

جدول

۱-۵	مقایسه سیاست‌های HAS-RL (یک‌طرفه و دوطرفه) با بیس‌لاین بدون قید در سقف	
۲۶	$\kappa = 5$ نیوتن (رول‌اوت 10^6 گام)	
۲۸	۲-۵ ارزیابی زیروشات در سطوح مختلف سقف ایمنی اپراتور با policy واحد (بدون بازآموزی)	
۳-۵	تحلیل ابلیشن الف: اثر مؤلفه‌های پیش‌نگری بر خطای رهگیری جانبی (میانگین $\pm$)	
۲۹	انحراف معیار روی ۳ بذری	
۴-۵	تحلیل ابلیشن ب: مقایسه روش‌های تنظیم متغیر دوگان در نسخه تک‌طرفه سقفی	
۲۹	(میانگین $\pm$ انحراف معیار روی ۳ بذری)	
۵-۵	ارزیابی پنجره دوطرفه اپراتور با policy واحد و بدون بازآموزی (10^6 درصد حضور	
۳۱	درون پنجره)	
۶-۵	مقایسه روش‌های تنظیم ضریب لاگرانژ در نسخه دوطرفه (پنجره‌ای) SBL (میانگین	
۳۲	$\pm$ انحراف معیار روی ۳ بذری)	
۳۹	۷ فرایارامترهای یادگیری تقویتی، باندیت و شبیه‌ساز در چارچوب HAS-RL	

فهرست نمادها

نماد	مفهوم
κ	سقف ایمنی نیروی تماس تنظیم شده توسط اپراتور
κ_{low}	کران پایینی پنجره ایمنی نیروی تماس
κ_{high}	کران بالایی پنجره ایمنی نیروی تماس
λ	متغیر دوگان یا ضریب جریمه لاگرانژ
λ_t	ضریب لاگرانژ هموار شده فعال در دوره t
$\bar{\lambda}_t^{\text{exp}}$	امید ریاضی ضریب لاگرانژ حاصل از توزیع بازوهای باندیت
τ	ضریب هموارسازی در میانگین متحرک نمایی
π_θ	policy با بردار پارامترهای θ
θ	بردار پارامترها و وزن های شبکه عصبی policy (اکتور)
ϕ_R	پارامترهای شبکه عصبی کریتیک پاداش
ϕ_C	پارامترهای شبکه عصبی کریتیک هزینه ایمنی
s_t	بردار state و مشاهده محیط در گام زمانی t
a_t	بردار action ایجنت در گام زمانی t
r_t	پاداش متراکم تک گام
c_t	هزینه ایمنی سخت تک گام به عنوان اندیکاتور نقض قید
$J_r(\pi)$	بازدهی تنزیل شده مورد انتظار تابع پاداش
$J_c(\pi)$	هزینه تنزیل شده مورد انتظار ایمنی
d	بودجه مجاز نقض قید ایمنی در هر گام
$\hat{A}_t^{\text{safe}}$	برآورد ادونتج ایمن ترکیبی در به روزرسانی گرادیان اکتور
$\hat{A}_t^R$	برآورد ادونتج تعمیم یافته GAE برای پاداش
$\hat{A}_t^C$	برآورد ادونتج تعمیم یافته GAE برای هزینه ایمنی
$V_R(s)$	تابع ارزش تخمینی کریتیک پاداش

تابع ارزش تخمینی کریتیک هزینه ایمنی	$V_C(s)$
ضریب دیسکانت زمانی	γ
پارامتر واپاشی اثر در روش برآورد مزیت تعمیم یافته GAE	λ_{GAE}
پارامتر برش نسبت احتمالات در الگوریتم PPO	ϵ
نسبت احتمال action در policy جدید به policy پیشین	ρ_t
نیروی تماس عمودی لحظه‌ای پروب بر روی سطح بافت بر حسب نیوتن	F
نیروی تماس بهینه برای بالاترین کیفیت اتصال آکوستیک	F_{opt}
حداقل نیروی تماس لازم جهت اتصال اولیه ژل و بافت	F_{min}
نیروی تماس هدف بودجه آگاه درون پنجره ایمن	F_{tgt}
موقعیت جانبی مرجع خط مرکزی ستون فقرات با مدل سینوسی اسکولیوز	$y^*(x)$
خطای انحراف جانبی پروب نسبت به خط مرکزی ستون فقرات	$e(x)$
خطای جانبی پیش‌بین در افق ۵ و ۱۵ گام زمانی آینده	e^{+5}, e^{+15}
شاخص پیوسته کیفیت تصویر سونوگرافی	$q(F, e)$
وزن تخصیص یافته به بازوی i ام در الگوریتم باندیت EXP3	w_i
نرخ یادگیری به‌روزرسانی وزن‌های باندیت	η
طول افق زمانی هر اپیزود اسکن	T
فضای state در CMDP	$\mathcal{S}$
فضای action در CMDP	$\mathcal{A}$

فصل اول

مقدمه و کلیات پژوهش

۱-۱ مقدمه و انگیزه پژوهش

هدف این پژوهش، توسعه یک سامانه رباتیک کمکی و ارگونومیک (Robot-Assisted Ultrasound) تحت نظارت و کنترل پیوسته پزشک برای تسهیل تصویربرداری سونوگرافی تشخیصی و کاهش آسیب‌های اسکلتی-عضلانی شغلی در متخصصان بالینی است. در تصویربرداری سونوگرافی، متخصصان ساعت‌های متمادی ناچارند پروب را با نیروی یکنواخت و وضعیت ثابت روی بدن بیمار فشرده نگه‌دارند که این امر به شیوع بالای اختلالات اسکلتی-عضلانی شغلی منجر می‌گردد. به کارگیری یک بازوی رباتیک همکار به عنوان ابزار کمکی در کنار پزشک (Shared Control)، بار خستگی فیزیکی ناشی از اعمال فشار یکنواخت را کاهش می‌دهد؛ در حالی که هدایت بالینی و تعیین حدود ایمنی بیمار همواره در اختیار مستقیم پزشک باقی می‌ماند. با این حال، تماس فیزیکی مستقیم پروب با بدن بیمار سبب می‌شود که مقوله ایمنی نیرو به عنوان یک الزام بنیادین و غیرقابل مصالحه تعریف شود، نه صرفاً یک هدف اختیاری در تابع پاداش. یادگیری تقویتی^۱ ابزاری کارآمد برای یادگیری policy مناسب جهت تنظیم تطبیقی نیرو و state پروب به شمار می‌رود؛ چرا که رابطه میان نیروی اعمال‌شده و کیفیت تصویر خروجی کاملاً غیرخطی است و مدل‌سازی تحلیلی آن بسیار دشوار است. با این حال، ایجنسی که صرفاً به دنبال بیشینه‌سازی پاداش کیفیت باشد، تمایل دارد برای اتصال آکوستیک بهتر نیرو را بیش از اندازه افزایش دهد. در غیاب یک قید صریح، چنین رفتاری می‌تواند به بافت بیمار آسیب برساند. این مسئله، چالش و تضاد بنیادین میان کیفیت تصویر تشخیصی و ایمنی بیمار است که یادگیری تقویتی ایمن باید به حل آن بپردازد.

۲-۱ بررسی شکاف‌های پژوهشی در مطالعات پیشین

دو دسته از پژوهش‌های اخیر صورت‌بندی این مسئله را پایه‌گذاری کرده‌اند، اما هر یک دارای شکافی هستند که این پایان‌نامه آن را برطرف می‌کند:

الف) بهینه‌سازی policy آگاه از قید در سونوگرافی رباتیک (Constraint-Aware Policy)
 در پژوهش دوان و همکاران [۱] که نخستین کاربرد یادگیری تقویتی ایمن رسمی در این حوزه است، تنظیم نیروی سونوگرافی در قالب یک CMDP^۲ مدل‌سازی شده است. این روش با ادغام به‌روزرسانی‌های ناحیه اعتماد^۳ درون یک حل‌کننده نقطه درونی دوگان-اولیه

^۱ Reinforcement Learning

^۲ Constrained Markov Decision Process

^۳ Trust Region

مسئله را حل کرده و با یک الگوی نرخ یادگیری مبتنی بر تقلید، تغییرات policy در گام‌های متوالی را پایدار می‌سازد. با این حال، قید نیرو در این روش یک آستانه منفرد و ثابت است که در طول آموزش فیکس شده است. بنابراین، چنانچه آستانه تحمل بیمار تغییر یابد (برای نمونه در مواجهه با یک بیمار حساس‌تر، تغییر ناحیه تصویربرداری از بدن، یا بنا به نظر پزشک)، سیستم نیازمند آموزش مجدد یک policy جدید از ابتدا خواهد بود.

ب) بهینه‌سازی آنلاین در یادگیری تقویتی ایمن آفلاین (Online Optimization for Safe RL): در پژوهش چمینگویی و همکاران با عنوان O3SRL [۲]، از الگوریتم باندیت با نام EXP3 برای انتخاب آنلاین ضریب لاگرانژ در طول آموزش آفلاین^۴ استفاده شده و کران‌های تحلیلی پشیمانی^۵ برای آن ارائه شده است. متغیر دوگان در این روش فاقد کانتکست است (تنها برای یک بودجه ثابت به کار می‌رود)؛ افزون بر این، همان‌طور که در نتایج تجربی این پایان‌نامه نشان داده خواهد شد، سمپل‌گیری گسسته از بازوهای متغیر دوگان در هر دوره و اعمال مستقیم آن به ادونتج در گرادیان policy آنلاین، واریانس بسیار بزرگی به سیگنال یادگیری اکتور تزریق کرده و روند آموزش را کاملاً ناپایدار می‌سازد.

۳-۱ نوآوری‌ها و دستاوردهای پژوهش

در این پایان‌نامه، فریم‌ورک HAS-RL^۶ معرفی شده و چهار نوآوری مشخص ارائه می‌گردد که همگی در قالب آزمایش‌های ابلیشن کنترل‌شده با متغیر واحد، بذرها و بودجه یکسان اعتبارسنجی شده‌اند:

۱. الف) تنظیم آنلاین فشار ایمنی به صورت زیروشات (Operator-Conditioned Zero-Shot Safety):

به جای تعیین یک سقف نیروی ثابت، مقدار آستانه تعیین‌شده توسط پزشک مستقیماً به عنوان ورودی آنلاین در بردار مشاهده قرار گرفته و یک policy واحد بر روی یک برنامه آموزشی مرحله‌ای^۷ تصادفی آموزش داده می‌شود. این policy می‌تواند در زمان اجرا، نیروی تماس را بدون نیاز به هیچ‌گونه بازآموزی با حد جدید تطبیق دهد، تغییرات آنلاین سقف فشار را حتی در حین اسکن دنبال کند و هرگز از آستانه مجاز فعال عبور ننماید.

۲. ب) سازوکار لاگرانژ باندیتی هموارشده (SBL)^۸: مزیت استفاده از بازوهای گسسته متغیر

^۴ Offline RL

^۵ Regret Bounds

^۶ Human-Adaptive Safe Reinforcement Learning

^۷ Curriculum Learning

^۸ Smoothed Bandit-Lagrangian

دوگان با الهام از روش O3SRL [۲] (که بازه جریمه کران‌دار و تفسیرپذیری فراهم می‌کند) حفظ شده است. اما برای انتقال موفق این ایده آفلاین به یک محیط آنلاین، میانگین متحرک نمایی^۹ از امید ریاضی متغیر دوگان به گام به‌روزرسانی policy اعمال می‌شود. این رویکرد، پرش‌های شدید گرادیان در هر دوره را که موجب ناپایداری تطبیق مستقیم باندیت می‌شوند، حذف می‌کند.

۳. ج) کنترل و رهگیری پیش‌نگر خطای مسیر (Anticipatory Tracking via Look-Ahead):

در کنترلگرهای واکنشی که فقط خطای لحظه‌ای را ارزیابی می‌کنند، حرکت پروب روی انحنای ستون فقرات دچار تأخیر زمانی می‌شود. در این پژوهش با افزودن پیش‌نگری کوتاه‌مدت از خطای جانبی (e_{+5}, e_{+15}) به بردار state (بر اساس اطلاعات پیش‌اسکن تشخیصی یا اطلس آناتومیک بیمار)، ربات کمکی پیش از رسیدن به انحنای موقعیت پروب را تنظیم می‌کند؛ این سازوکار خطای جذر میانگین مربعات (RMSE) رهگیری روی انحنای ستون فقرات با مدل اسکولیوز را به میزان ۲۸ درصد کاهش می‌دهد.

۴. د) ایمنی پنجره آکوستیک دوطرفه (Two-Sided Acoustic-Window Safety): ایمنی

نیروی سونوگرافی نه به عنوان یک سقف یک‌طرفه، بلکه به شکل یک پنجره بالینی $[\kappa_{\text{low}}, \kappa_{\text{high}}]$ شامل حداقل نیروی لازم برای اتصال آکوستیک و حداکثر نیروی ایمن مدل‌سازی شده است. این کران پایین، ضعف ایمنی صرفاً سقفی را برطرف می‌سازد؛ این سازوکار، بازه استفاده‌نشده نیرو را فعال کرده و قید ایمنی را به یک قید کاملاً مؤثر و اکتیو تبدیل می‌کند.


همچنین یک محیط شبیه‌ساز سبک و مستقل برای سونوگرافی ارائه شده است که فریم‌های دوبعدی حالت B را تولید می‌کند و تمام محاسبات آن به طور کامل روی پردازنده مرکزی (بدون نیاز به کارت گرافیک یا ابزارهای جانبی حجیم) اجرا می‌شود.

۴-۱ محدوده و شفافیت علمی دستاوردها

در این پایان‌نامه، حدود دستاوردهای هر بخش به صراحت و با شفافیت علمی بیان شده است. نتایج قابلیت زیروشات با سقف متغیر قوی و نوآورانه است. در خصوص سازوکار لاگرانژ باندیتی هموار شده (SBL)، نتایج مطلوب اما واقع‌بینانه است: بر اساس تابع پاداش طراحی‌شده، روش پیشنهادی در کیفیت تصویر اندکی بهتر از روش استاندارد صعود دوگان عمل می‌کند، اما مزیت اصلی و قطعی آن، پایداری

^۹Exponential Moving Average (EMA)

بالای آموزش در مقایسه با باندیت خام است؛ فاصله کیفی این روش با صعود دوگان در محدوده یک انحراف معیار بذر قرار دارد که این موضوع در بخش نتایج و بحث به روشنی مورد تحلیل قرار گرفته است.



شکل ۱-۱: انطباق زیروشات policy چارچوب HAS-RL با تغییر آنلاین حد فشار در حین اسکن (۱۱ → ۴ → ۹ نیوتن). خط چین قرمز سقف ایمنی فعال و منحنی آبی پاسخ دینامیکی policy را بدون نقض قید نشان می‌دهد.

۵-۱ ساختار پایان‌نامه

ادامه این پایان‌نامه به شرح زیر ساختار بندی شده است: در فصل دوم، پیشینه پژوهش‌های مرتبط و مبانی نظری شامل CMDP، الگوریتم PPO، برآورد مزیت تعمیم‌یافته (GAE) و روش‌های لاگرانژی تشریح می‌شوند. در فصل سوم، معماری و روابط حاکم بر شبیه‌ساز اولتراسوند HAS-RL شامل مدل سینماتیک، کنترل امپدانس نیرو، مدل رندرینگ فریم‌های حالت B و توابع پاداش و هزینه ارائه می‌گردد. در فصل چهارم، اجزای فریم‌ورک پیشنهادی HAS-RL از جمله شرطی‌سازی policy، الگوریتم SBL، رهگیری پیش‌بینانه و مدل پنجره دوطرفه به تفصیل بیان می‌شوند. در نهایت، در فصل پنجم، نتایج تجربی، آزمایش‌های ابلیشن، بحث و بررسی علمی، محدودیت‌های پژوهش و مسیرهای آینده ارائه خواهند شد.

فصل دوم

پیشینه پژوهش و مبانی نظری

۱-۲ مروری بر پیشینه پژوهش

در این بخش، ادبیات پژوهش در چهار حوزه مرتبط مورد بررسی قرار می‌گیرد: چارچوب‌های یادگیری تقویتی ایمن، روش‌های تثبیت متغیر دوگان لاگرانژ، الگوریتم‌های باندیتی در یادگیری ایمن آفلاین، و کاربردهای یادگیری تقویتی در سونوگرافی رباطیک.

۱-۱-۲ یادگیری تقویتی ایمن و CMDP

صورت‌بندی استاندارد برای مسائل کنترلی دارای قید ایمنی، فرایند تصمیم‌گیری مارکوف مقید^۱ است [۳]. در این چارچوب، هدف ایجنت بیشینه‌سازی پاداش مورد انتظار با رعایت یک سقف بودجه برای هزینه مورد انتظار است. برای حل این مسئله، دو خانواده اصلی از روش‌ها وجود دارند:

۱. الف) روش‌های ناحیه اعتماد و تصویرسازی: روش‌هایی نظیر بهینه‌سازی policy مقید^۲ [۴] که قید ایمنی را از طریق تعریف یک ناحیه اعتماد در هر گام بهینه‌سازی تحمیل می‌کنند. این روش‌ها از نظر تئوری بهبود یکنواخت policy را تضمین می‌کنند، اما نیازمند محاسبات مرتبه دوم و وارون‌سازی ماتریس فیشر هستند که هزینه محاسباتی بالایی به همراه دارد.

۲. ب) روش‌های آزادسازی لاگرانژ: روش‌هایی که قید را در قالب یک جریمه خطی با ضریب لاگرانژ λ وارد تابع هدف کرده و این متغیر دوگان را از طریق روش صعود دوگان^۳ بهینه‌سازی می‌کنند [۵، ۶]. الگوریتم لاگرانژی بر پایه PPO، به دلیل سادگی، مقیاس‌پذیری بالا و بی‌نیازی از اطلاعات مرتبه دوم، به عنوان بیس‌لاین اصلی در این پژوهش انتخاب شده است.

۲-۱-۲ تثبیت و کنترل نوسانات متغیر دوگان لاگرانژ

یکی از چالش‌های شناخته‌شده در روش صعود دوگان کلاسیک، پدیده نوسان شدید است: مقدار متغیر دوگان دچار جهش‌های مکرر می‌شود که این امر موجب می‌گردد رفتار policy میان عملکرد بی‌محابا (نقض مکرر قید) و محافظه‌کاری افراطی (افت شدید پاداش) نوسان کند. استوک و همکاران [۷] برای مهار این پدیده، کنترل‌کننده PID را بر روی خطای قید اعمال کردند که به روش لاگرانژ-PID موسوم است. سازوکار لاگرانژ باندیتی هموارشده پیشنهادی ما (SBL) در این پایان‌نامه، از نظر هدف (هموارسازی

^۱ Constrained Markov Decision Process (CMDP)

^۲ Constrained Policy Optimization (CPO)

^۳ Dual Ascent

سیگنال متغیر دوگان) با این رویکرد هم‌راستاست، اما سازوکار آن تفاوت بنیادین دارد: به جای استفاده از یک کنترل‌کننده پیوسته، روش ما یک توزیع باندیتی بر روی مجموعه‌ای از مقادیر گسسته و کران‌دار نگه‌داشته و امید ریاضی آن را با یک فیلتر پایین‌گذر هموار می‌سازد. ساختار باندیتی سقفی سخت و تفسیرپذیر برای جریمه فراهم می‌کند و فیلتر میانگین متحرک نمایی نوسانات را برطرف می‌سازد.

۳-۱-۲ متغیرهای دوگان باندیتی و یادگیری تقویتی آفلاین

چمینگویی و همکاران در چارچوب O3SRL [۲]، مسئله انتخاب آنلاین متغیر دوگان را در قالب یک مسئله باندیت با حریف متخاصم (Adversarial Bandit) و با استفاده از الگوریتم EXP3 [۸] فرمول‌بندی کرده و آن را در یادگیری تقویتی ایمن آفلاین به کار گرفتند. روش پیشنهادی ما ساختار الگوریتم EXP3 را وام می‌گیرد، اما برای یادگیری گرادیان policy آنلاین بازطراحی شده است؛ جایی که نشان می‌دهیم نمونه‌برداری تصادفی از بازوهای گسسته در هر دوره موجب ناپایداری شدید می‌شود و هموارسازی پیشنهادی دقیقاً این مشکل را حل می‌کند.

۴-۱-۲ تصویربرداری اولتراسوند رباتیک کمکی و یادگیری تقویتی ایمن (Robot-Assisted)

(Assisted Ultrasound)

تنظیم رباتیک کمکی پروب سونوگرافی با استفاده از یادگیری تقویتی نخستین بار توسط هاسه و همکاران [۹] برای معاینه ستون فقرات و ناحیه خاجی معرفی شد. دوان و همکاران [۱] با بسط این ایده، برای نخستین بار یادگیری تقویتی ایمن رسمی را در این حوزه پیاده کردند. آن‌ها تنظیم نیروی سونوگرافی را به صورت یک CMDP مدل‌سازی کرده و آن را با روش CPO مبتنی بر روش نقطه درونی دوگان-اولیه حل نمودند. همچنین برای حفظ پایداری آموزش، نرخ یادگیری گرادیان policy را با رویکردی مبتنی بر تقلید طراحی کردند تا نزدیکی policy‌های متوالی حفظ شود. با وجود دستیابی به ضمانت‌های ریاضی، قید نیرو در روش آن‌ها یک مقدار ثابت و فیکس شده در فرایند آموزش است. نوآوری اصلی چارچوب پیشنهادی HAS-RL تبدیل این آستانه ثابت به یک ورودی تنظیمی آنلاین توسط پزشک است که امکان دستیابی به طیف پیوسته‌ای از رفتارهای ایمن را با یک policy واحد فراهم می‌آورد.

۲-۲ مبانی نظری و صورت‌بندی ریاضی

در این بخش، تعاریف پایه ریاضی که زیربنای چارچوب پیشنهادی را تشکیل می‌دهند، ارائه می‌گردد.

۱-۲-۲ فرایند تصمیم‌گیری مارکوف مقید (CMDP)

فرایند اسکن به صورت یک CMDP شش‌تایی $(\mathcal{S}, \mathcal{A}, \mathcal{P}, r, c, \gamma)$ تعریف می‌شود که در آن فضای state، $\mathcal{A}$ فضای action، $\mathcal{P} : \mathcal{S} \times \mathcal{A} \rightarrow \Delta(\mathcal{S})$ تابع انتقال احتمالاتی، $r : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ تابع پاداش، $c : \mathcal{S} \times \mathcal{A} \rightarrow \{0, 1\}$ هزینه نقض ایمنی در هر گام، و $\gamma \in [0, 1)$ ضریب دیسکانت زمانی است. برای یک policy پارامتری π_θ ، بازده پاداش مورد انتظار $J_r(\pi_\theta)$ و هزینه تنزیل‌شده نقض ایمنی $J_c(\pi_\theta)$ به شرح زیر تعریف می‌شوند:

$$J_r(\pi_\theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \right], \quad J_c(\pi_\theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{t=0}^{\infty} \gamma^t c(s_t, a_t) \right] \quad (1-2)$$

هدف مسئله کنترل بهینه‌سازی policy با رعایت قید بودجه مجاز نقض در هر گام است:

$$\max_{\theta} J_r(\pi_\theta) \quad \text{به شرط آن که} \quad \mathbb{E}[c] \leq d \quad (2-2)$$

که در آن d نرخ مجاز نقض قید در هر گام است (در این پژوهش $d = 0.2$ در نظر گرفته شده است).

۲-۲-۲ الگوریتم PPO با دو کریتیک و برآورد مزیت تعمیم‌یافته (GAE)

به منظور بهینه‌سازی پارامترهای policy θ ، از تابع هدف جانشین برش‌خورده در الگوریتم PPO^۴ [۱۰] استفاده می‌شود:

$$\mathcal{L}^{\text{clip}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(\rho_t \hat{A}_t, \text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (3-2)$$

که در آن نسبت احتمالاتی به صورت $\rho_t = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ و پارامتر برش $\epsilon = 0.2$ تعریف می‌شود. از آنجا که پاداش وظیفه و هزینه ایمنی سیگنال‌هایی متمایز و در اغلب شرایط متعارض هستند، دو شبکه کریتیک مجزا نگهداری می‌شوند: کریتیک پاداش $V_R(s)$ و کریتیک هزینه $V_C(s)$. برای ایجاد

موازنه دقیق میان واریانس و بایاس در تخمین ادونتج^۵، از روش برآورد مزیت تعمیم یافته (GAE)^۶ [۱۱] بهره گرفته می شود. به جای مجموع نامتناهی، این برآورد روی مسیرهای رول اوت^۷ با طول متناهی T و با در نظر گرفتن شرایط مرزی پایان هر اپیزود محاسبه می شود. برای سیگنال پاداش، ابتدا خطای تفاضل زمانی (TD)^۸ تک گام محاسبه می شود:

$$\delta_t^R = r_t + \gamma(1 - d_t)V_R(s_{t+1}) - V_R(s_t) \quad (۴-۲)$$

که در آن $d_t \in \{0, 1\}$ نشانگر پایان اپیزود در گام t است. سپس مقدار ادونتج پاداش با GAE برابر است با مجموع تنزیل شده این خطاها تا انتهای مسیر:

$$\hat{A}_t^R = \sum_{l=0}^{T-t-1} (\gamma \lambda_{\text{GAE}})^l \delta_{t+l}^R \quad (۵-۲)$$

که در آن $\gamma = 0.99$ ضریب دیسکانت و $\lambda_{\text{GAE}} = 0.95$ پارامتر واپاشی اثر است. این رابطه به صورت بازگشتی رو به عقب به فرم زیر محاسبه می شود:

$$\hat{A}_t^R = \delta_t^R + \gamma \lambda_{\text{GAE}}(1 - d_t)\hat{A}_{t+1}^R \quad (۶-۲)$$

ادونتج هزینه ایمنی $\hat{A}_t^C$ نیز دقیقاً با رابطه ای مشابه و با استفاده از سیگنال هزینه c_t و کریتیک هزینه $V_C(s)$ به دست می آید. هر دو ادونتج پیش از اعمال به گرادیان به طور مستقل نرمال سازی می شوند.

۳-۲-۲ آزادسازی لاگرانژ و ادونتج ترکیبی ایمن

تابع لاگرانژ متناظر با مسئله بهینه سازی مقید (۲-۲) به صورت زیر تعریف می شود:

$$\mathcal{L}(\theta, \lambda) = J_r(\pi_\theta) - \lambda(J_c(\pi_\theta) - d), \quad \lambda \geq 0 \quad (۷-۲)$$

Advantage^۵

Generalized Advantage Estimation^۶

Rollout^۷

Temporal Difference^۸

در چارچوب گرادیان policy آنلاین، این آزادسازی حکم می‌کند که شبکه اکتور بر اساس یک سیگنال ادونتیج ترکیبی ایمن به‌روزرسانی شود:

$$\hat{A}_t^{\text{safe}} = \hat{A}_t^R - \lambda \hat{A}_t^C \quad (۸-۲)$$

ضریب لاگرانژ λ موازنه دینامیکی میان پیشینه‌سازی پاداش و جریمه نقض قید را تنظیم می‌نماید. چگونگی تعیین و پایداری این ضریب در هر دوره، محور اصلی طراحی الگوریتمی در این پژوهش است.

فصل سوم

شبیه‌ساز اولتراسوند HAS-RL

۳-۱ انگیزه توسعه و محدودیت‌های محیط‌های پیشین

با اتکا به الگوی ناوبری و اسکن ستون فقرات که توسط هاسه و همکاران [۹] معرفی شد، یک محدودیت کلیدی در محیط‌های موجود برای یادگیری تقویتی ایمن مشاهده می‌شود: محیط متن‌باز آن‌ها بر پایه ناوبری روی یک گرید-ورلد آفلاین^۱ از تصاویر پیش‌ثبت‌شده کار می‌کند. از آنجا که این تصاویر از پیش ضبط شده‌اند، نیروی تماس در زمان جمع‌آوری داده‌ها ثابت بوده است؛ در نتیجه برای ایجنت ناممکن است که فشار تماس را به صورت پویا تغییر دهد یا فیزیک امیدانس تماس را در لحظه تجربه نماید.

برای مطالعه ایمنی نیروی پیوسته، تمامی آزمایش‌های این پژوهش در یک شبیه‌ساز فیزیکی پویا و مستقل (بدون نیاز به فایل‌های حجیم خارجی، با اجرای کامل روی پردازنده مرکزی) انجام شده است. این شبیه‌ساز سه مؤلفه فیزیکی بنیادین مرتبط با ایمنی بلادرنگ را پیاده‌سازی می‌کند: سینماتیک حرکت پروب، کنترل امیدانسی پایین‌گذر نیرو، و مدل تحلیلی فریم‌های دوبعدی حالت B که تصویر را بر اساس فشار لحظه‌ای بازتولید می‌کند. هر اپیزود شبیه‌سازی، یک پیمایش کامل از بالا به پایین ستون فقرات در طول $T = ۱۰۰$ گام است.

۳-۲ سینماتیک حرکت و کنترل امیدانس نیرو

پروب با سرعت طولی ثابت $v_x = ۱/T$ در طول محور طولی نرمال‌شده $x \in [۰, ۱]$ به سمت جلو حرکت می‌کند. خط مرکزی واقعی ستون فقرات با یک تابع سینوسی اسکولیوز به صورت زیر مدل شده است:

$$y^*(x) = A \sin(۲/۵\pi x), \quad A = ۰/۰۷ \quad (۱-۳)$$

که پروب باید آن را در جهت جانبی دنبال کند. بردار action ایجنت دو بعدی است: $a = (a_{lat}, a_{force}) \in [-۱, ۱]^۲$ که هدایت جانبی پروب و نرخ تغییر نیرو را کنترل می‌کند:

$$y \leftarrow \text{clip}(y + ۰/۰۲۲ a_{lat}, -۰/۲۵, ۰/۲۵) \quad (۲-۳)$$

$$F \leftarrow \text{clip}(F + ۰/۷ a_{force}, ۰, ۲۰) \quad (\text{بر حسب نیوتن}) \quad (۳-۳)$$

^۱Offline Grid-World

به‌روزرسانی نیرو یک مدل امپدانسی پایین‌گذر است: ایجنت یک تغییر کران‌دار در نیرو (حداکثر ۰/۷ نیوتن در هر گام) را فرمان می‌دهد، نه یک نیروی لحظه‌ای ناگهانی؛ این رفتار دقیقاً پاسخ نرم یک عملگر رباتیک در تماس با بافت را منعکس می‌سازد. خطای انحراف جانبی به صورت $e(x) = y - y^*(x)$ تعریف می‌شود.

۳-۳ مدل تحلیلی کیفیت تصویر و رندرینگ حالت B

شاخص کیفیت تصویر $q \in [0, 1]$ یک تقریب مشتق‌پذیر است که دو مؤلفه اساسی مورد توجه سونوگرافر را پاداش می‌دهد: برقراری اتصال آکوستیک کافی و انطباق بر مرکز هدف:


$$q(F, e) = \begin{cases} 0.05 \left(\frac{F}{F_{\min}} \right), & F < F_{\min} \\ 0.65 \underbrace{\exp \left(-\frac{1}{2} \left(\frac{F - F_{\text{opt}}}{3.2} \right)^2 \right)}_{\text{اتصال آکوستیک}} + 0.35 \underbrace{\exp \left(-\frac{1}{2} \left(\frac{e}{0.15} \right)^2 \right)}_{\text{انطباق بر مرکز}}, & F \geq F_{\min} \end{cases} \quad (3-4)$$

که در آن $F_{\min} = 1/0$ نیوتن آستانه حداقلی اتصال ژل با پوست و $F_{\text{opt}} = 7/0$ نیوتن نقطه اوج بازه آکوستیک است. نکته اساسی آن است که کیفیت تصویر با افزایش نیرو تا رسیدن به F_{opt} افزایش می‌یابد؛ دقیقاً به همین علت است که یک ایجنت بدون قید تمایل دارد فشار بیش از حد اعمال نماید.

به منظور ارزیابی کیفی و مصورسازی تشخیصی، شبیه‌ساز فریم‌های دوبعدی حالت B-mode را به صورت بلادرنگ رندر می‌کند (شکل ۱-۳) که نشان‌دهنده نحوه عملکرد محیط تشخیصی است؛ این مدل پدیده‌های فیزیکی سونوگرافی شامل نویز اسپکل ریلی^۲، تضعیف عمقی امواج همراه با جبران بهره با زمان^۳، یک کمان هاپیراکوی استخوانی مهره که موقعیت جانبی آن با خطای انحراف e جابه‌جا می‌شود، و سایه آکوستیک تاریک زیر استخوان را به دقت بازسازی می‌نماید.

^۲ Rayleigh Speckle

^۳ Time-Gain Compensation (TGC)



شکل ۳-۱: نمونه فریم‌های دوبعدی حالت B-mode تولیدشده توسط محیط شبیه‌ساز سونوگرافی (نمایش در هر ۱۰ گام پویش). این تصویر نحوه عملکرد محیط سونوگرافی را نشان می‌دهد که در آن اثرات فیزیکی امواج اولتراسوند نظیر نویز اسپکل، بازتاب پرنعکاس کمان استخوانی ستون فقرات، و سایه آکوستیک پشت مهره بر مبنای موقعیت و وضعیت تماس پروب به صورت پیوسته رندر می‌گردند.

۴-۳ صورت‌بندی تابع پاداش ترکیبی و هزینه ایمنی

تابع پاداش ترکیبی^۴ رفتارهای رهگیری، کیفیت تصویر و همواری action را جهت‌دهی می‌کند:

$$r = \underbrace{0.5 q}_{\text{کیفیت تصویر}} + \underbrace{0.3 \exp\left(-\frac{1}{2} \left(\frac{e}{0.15}\right)^2\right)}_{\text{پاداش انطباق بر مرکز}} - \underbrace{(0.35 e^2 + 0.4 |e|)}_{\text{جریمه خطای جانبی}} \quad (5-3)$$

$$- \underbrace{0.5 (F - F_{\text{tgt}})^2}_{\text{هدایت به هدف آگاه از بودجه}} - \underbrace{0.15 \|a - a_{\text{prev}}\|^2}_{\text{همواری action}} - \underbrace{0.5 \|a\|^2}_{\text{جریمه تلاش کنترلی}}$$

که در آن هدف آگاه از بودجه $F_{\text{tgt}} = \min(F_{\text{opt}}, \kappa - 0.4)$ نیرو را به سمت بالاترین مقدار ایمن در سقف فعال جذب می‌نماید. هزینه ایمنی در هر گام، یک متغیر نشانگر صریح از تخطی نیرو از سقف اپراتور است:

$$c = \mathbb{1}[F > \kappa] \quad (6-3)$$

لازم به ذکر است که جمله آگاه از بودجه در پاداش سبب می‌شود که خود تابع پاداش نیز تا حدی نسبت به ایمنی آگاه باشد؛ این طراحی کاملاً منطبق بر واقعیت مهندسی است (یک کنترل‌کننده خوب نباید از ابتدا چسبیدن به مرز خطر را هدف بگیرد)، اما به این معناست که سازوکار لاگرانژ تنها عامل تأمین ایمنی در مدل نیست.

Dense Reward^۴

۵-۳ بردار مشاهده: سقف ایمنی و پیش‌نگری آینده

بردار مشاهده 10 بعدی ایجنت به شرح زیر است:

$$s = [x, y, e, \dot{e}, F, \dot{F}, q, \kappa, e^{+5}, e^{+15}] \quad (7-3)$$

که در آن $\dot{e}$ و $\dot{F}$ تفاضل‌های تک‌گام هستند. سه مؤلفه انتهایی، نوآوری‌های ساختاری این پژوهش هستند: κ سقف تنظیمی اپراتور است، و $e^{+5} = y - y^*(x + 5v_x)$ و $e^{+15} = y - y^*(x + 15v_x)$ خطاهای انحراف جانبی پیش‌بین در 5 و 15 گام آینده هستند. در آزمایش‌های ابلیشن بدون پیش‌نگری، این دو مؤلفه با صفر مقداردهی شده و ساختار شبکه بدون تغییر باقی می‌ماند.

فصل چهارم

چارچوب پیشنهادی HAS-RL

در این فصل، ساختار روش پیشنهادی HAS-RL شامل چهار نوآوری الگوریتمی تشریح می‌گردد: تنظیم آنلاین فشار ایمنی به صورت زیروشات، سازوکار لاگرانژ باندیتی هموارشده، رهگیری پیش‌بینانه خطا، و بسط به پنجره آکوستیک دوطرفه.

۴-۱ تنظیم آنلاین فشار ایمنی به صورت زیروشات

به جای آموزش یک policy جداگانه برای هر آستانه نیرو، مقدار آستانه به عنوان یک ورودی به policy داده می‌شود. از آنجا که سقف ایمنی κ در بردار مشاهده (۳-۷)، در نیروی هدف آگاه از بودجه $F_{tgt} = \min(F_{opt}, \kappa - \epsilon/4)$ در تابع پاداش، و در تابع هزینه ایمنی (۳-۶) حضور دارد، policy $\pi_\theta(a | s, \kappa)$ و هر دو شبکه کریٹیک $V_C(s, \kappa)$ و $V_R(s, \kappa)$ طیفی پیوسته از رفتارهای ایمن را فرامی‌گیرند. در طول فرایند آموزش، در آغاز هر اپیزود یک سقف ایمنی جدید به صورت تصادفی از توزیع یکنواخت $\kappa \sim \mathcal{U}[3, 12]$ نیوتن نمونه‌برداری می‌شود که در واقع یک برنامه یادگیری مرحله‌ای^۱ بر روی قیدهاست. در زمان استقرار و کاربرد بالینی، پزشک می‌تواند سقف مجاز κ را آزادانه در این بازه تنظیم کند یا حتی حد مجاز را به صورت آنلاین در حین اسکن تغییر دهد؛ policy واحد بدون نیاز به هیچ گام گرادسانی جدید یا جمع‌آوری داده، به صورت زیروشات به مقدار جدید پاسخ می‌دهد. این قابلیت است که نه روش‌های آستانه ثابت [۱] و نه روش‌های تک‌بودجه آفلاین [۲] قادر به ارائه آن نبوده‌اند.

۴-۲ سازوکار لاگرانژ باندیتی هموارشده (SBL)

این سازوکار ضریب لاگرانژ λ در رابطه (۲-۷) را در هر دوره به‌روزرسانی می‌کند. در این روش، $K = 5$ بازوی گسسته برای ضریب لاگرانژ با فواصل یکنواخت در بازه $[0, 5]$ در نظر گرفته شده و یک بردار وزن $w \in \mathbb{R}_{\geq 0}^K$ با الگوریتم EXP3 توزیع احتمالاتی نمونه‌برداری را به صورت $p_i = w_i / \sum_j w_j$ شکل می‌دهد.

۴-۲-۱ به‌روزرسانی وزن‌های باندیت

پس از به‌روزرسانی policy، بازوی نمونه‌برداری شده i_t بر اساس ارزش لاگرانژ تحقق‌یافته آن ارزیابی می‌شود: $\ell = \bar{r} - \lambda_{i_t}(\bar{c} - d)$ که در آن $\bar{r}$ میانگین پاداش بچ و $\bar{c}$ میانگین هزینه ایمنی بچ است. به منظور پایداری عددی، این مقدار به صورت $\ell/10$ مقیاس‌بندی شده و برآورد استاندارد وزن‌دهی شده با

^۱Curriculum Learning

احتمال اهمیت تشکیل می‌گردد:

$$\hat{\ell}_i = \text{clip} \left(\frac{\ell}{p_i}, -100, 100 \right) \mathbb{1}[i = i_t] \quad (1-4)$$

سپس وزن‌های الگوریتم وزن‌دهی نمایی با رابطه $w_i \leftarrow w_i \exp(-\eta \hat{\ell}_i)$ با نرخ یادگیری $\eta = 0.05$ به‌روزرسانی شده و مجدداً نرمال‌سازی می‌شوند. این بخش از سازوکار برگرفته از چارچوب O3SRL [۲] است؛ اما نوآوری اصلی روش ما در نحوه مصرف این ضریب توسط گرادیان policy آنلاین است که با دو ایده تعریف می‌شود:

۱. الف) استفاده از امید ریاضی به جای نمونه منفرد: یک الگوریتم باندیتی ساده، بازوی تصادفی λ_{i_t} را نمونه‌برداری کرده و مستقیماً اعمال می‌کند. این تخمین تک‌نمونه‌ای واریانس بالایی دارد و از آنجا که در ادونتج ضرب می‌شود، پرش‌های ناگهانی آن به گرادیان اکتور منتقل می‌گردد. در مقابل، ما امید ریاضی دقیق توزیع را محاسبه می‌کنیم که فاقد واریانس نمونه‌برداری است:

$$\bar{\lambda}_t^{\text{exp}} = \sum_{i=1}^K p_i \lambda_i \quad (2-4)$$

۲. ب) اعمال فیلتر پایین‌گذر میانگین متحرک نمایی: سپس یک فیلتر میانگین متحرک نمایی با ضریب هموارسازی $\tau = 0.05$ بر آن اعمال می‌شود:

$$\lambda_t = (1 - \tau) \lambda_{t-1} + \tau \bar{\lambda}_t^{\text{exp}} \quad (3-4)$$

بدین ترتیب ضریب لاگرانژی که به policy می‌رسد در طول دوره‌ها روندی هموار و پیوسته را طی می‌کند. این ضریب فعال λ_t برای ساخت ادونتج ترکیبی ایمن $\hat{A}_t^{\text{safe}} = \hat{A}_t^R - \lambda_t \hat{A}_t^C$ استفاده می‌شود.

مراحل کامل الگوریتم پیشنهادی در شبه‌کد الگوریتم ۱ خلاصه شده است.

۲-۲-۴ روش‌های مقایسه‌ای در تحلیل ابلیشن

برای سنجش اثر مستقیم سازوکار SBL، سه شیوه مختلف به‌روزرسانی ضریب لاگرانژ با ثابت نگه‌داشتن سایر شرایط پیاده‌سازی شده‌اند:

الگوریتم ۱ چارچوب پیشنهادی HAS-RL: بهینه‌سازی policy با دو کریتیک و لاگرانژ باندیتی هموار شده

```

1: Initialize actor  $\theta$ , critics  $\phi_R, \phi_C$ , initial state  $s_1$ , arms  $\{\lambda_i\}_{i=1}^N$ , weights  $w_i = 1$  for  $i = 1 \dots N$ 
2: for iteration  $k = 1, 2, \dots$  do
3:    $\theta_{\text{old}} \leftarrow \theta$ 
4:    $(s_1, \kappa_1, a_1, r_1, c_1, \dots, s_T) = \text{rollout}(s_1, \pi_{\theta_{\text{old}}})$   $\triangleright$  Conditioned on safety ceiling  $\kappa$ 
5:    $v_t^R = V_{\phi_R}(s_t, \kappa_t)$  and  $v_t^C = V_{\phi_C}(s_t, \kappa_t)$  for  $t = 1 \dots T$ 
6:    $(A_{1:T}^R, y_{1:T}^R) = \text{GAE}(r_{1:T}, v_{1:T}^R, \gamma, \lambda_{\text{GAE}})$   $\triangleright$  Reward advantage and returns
7:    $(A_{1:T}^C, y_{1:T}^C) = \text{GAE}(c_{1:T}, v_{1:T}^C, \gamma, \lambda_{\text{GAE}})$   $\triangleright$  Cost advantage and returns
8:    $p_i = \frac{w_i}{\sum_{j=1}^N w_j}$  for  $i = 1 \dots N$ ; sample arm  $i_k \sim p$ 
9:    $\bar{r} = \frac{1}{T} \sum_{t=1}^T r_t$ ;  $\bar{c} = \frac{1}{T} \sum_{t=1}^T c_t$ 
10:   $\lambda_k \leftarrow (1 - \tau)\lambda_{k-1} + \tau \sum_{i=1}^N p_i \lambda_i$   $\triangleright$  SBL smoothed multiplier (Eq. (4-3))
11:   $A_t^{\text{safe}} = A_t^R - \lambda_k A_t^C$  for  $t = 1 \dots T$   $\triangleright$  Composite safe advantage
12:  for  $m = 1 \dots M$  do
13:     $\rho_t = \frac{\pi_{\theta}(a_t|s_t, \kappa_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t, \kappa_t)}$  for  $t = 1 \dots T$ 
14:     $\tilde{\rho}_t = \text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon)$  for  $t = 1 \dots T$ 
15:     $\mathcal{L}(\theta) = -\frac{1}{T} \sum_{t=1}^T [\min(\rho_t A_t^{\text{safe}}, \tilde{\rho}_t A_t^{\text{safe}}) + c_{\text{ent}} \mathcal{H}(\pi_{\theta}(\cdot|s_t, \kappa_t))]$ 
16:     $\mathcal{L}(\phi_R) = \frac{1}{T} \sum_{t=1}^T (V_{\phi_R}(s_t, \kappa_t) - y_t^R)^2$ 
17:     $\mathcal{L}(\phi_C) = \frac{1}{T} \sum_{t=1}^T (V_{\phi_C}(s_t, \kappa_t) - y_t^C)^2$ 
18:    Update  $\theta, \phi_R, \phi_C$  via gradient descent on respective losses
19:  end for
20:   $\ell \leftarrow \bar{r} - \lambda_{i_k}(\bar{c} - d)$   $\triangleright$  Realized Lagrangian for sampled arm
21:   $\hat{\ell}_i \leftarrow \text{clip}(\ell/10, -100, 100) \frac{1[i=i_k]}{p_i}$  for  $i = 1 \dots N$   $\triangleright$  Importance-weighted loss
22:   $w_i \leftarrow w_i \exp(-\eta \hat{\ell}_i)$  for  $i = 1 \dots N$   $\triangleright$  EXP3 weight update
23: end for
    
```

• الف) صعود دوگان تصویر شده (dual): $\lambda_t = \text{clip}(\lambda_{t-1} + \eta_{\lambda}(\bar{c} - d), \circ, \lambda_{\text{max}})$ با نرخ یادگیری دوگان $\eta_{\lambda} = \circ/5$ (روش استاندارد در ادبیات).

• ب) باندیت خام آنلایین (exp3_raw): اعمال مستقیم بازوی نمونه‌برداری شده بدون هموارسازی $\lambda_t = \lambda_{i_t}$ (مشابه رویکرد O3SRL در محیط آنلایین).

• ج) روش پیشنهادی (sbl): ترکیب امید ریاضی توزیع با فیلتر میانگین متحرک نمایی مطابق رابطه (۳-۴).

۳-۴ رهگیری پیش‌بینانه خطا

یک کنترل‌کننده واکنشی که صرفاً خطای انحراف جانبی لحظه‌ای را می‌بیند، در تعقیب مسیرهای منحنی با تأخیر فاز مواجه می‌شود؛ چرا که تا زمان اندازه‌گیری خطا، پروب به جلو حرکت کرده است. با افزودن خطاهای پیش‌بین در گام‌های آینده (e^{+5} و e^{+15}) به بردار state، یک ساختار پیش‌نگری حداقلی و مبتنی بر مدل ایجاد می‌شود. از آنجا که هندسه ستون فقرات ویژگی تشریحی پیوسته بدن بیمار است، اطلاعات پیش‌بین در کاربرد عملی از طریق یک اسکن مقدماتی سریع یا تطبیق با اطلس‌های تشریحی در دسترس قرار دارد.

۴-۴ گذار از سقف منفرد به پنجره تشخیصی دوطرفه

شرطی‌سازی policy بر روی یک سقف یک‌طرفه با یک کاستی همراه است: policy انگیزه‌ای برای بهره‌برداری از بازه آزاد زیر سقف ندارد. در سقف $\kappa = 12$ نیوتن، نیروی آموخته‌شده روی ۷/۹۷ نیوتن متوقف می‌شود؛ زیرا هدف آگاه از بودجه $F_{tgt} = \min(F_{opt}, \kappa - 0.4)$ در نقطه اوج آکوستیک $F_{opt} = 7.0$ نیوتن اشباع می‌گردد. در نتیجه حدود ۳/۵ نیوتن از دامنه مجاز تعیین‌شده توسط پزشک بدون استفاده باقی می‌ماند.

این انگیزه موجب تعمیم سقف عددی به یک پنجره تشخیصی دوطرفه $[\kappa_{low}, \kappa_{high}]$ گردید که در آن پزشک هم حداقل نیروی لازم جهت اتصال آکوستیک و هم حداکثر نیروی مجاز ایمنی را تعیین می‌کند. برای اعمال این مدل، سه تغییر مشخص در سیستم اعمال می‌گردد:

۱. الف) گسترش بردار مشاهده: متغیر κ_{low} به بردار state افزوده شده و بعد بردار مشاهده از ۱۰ به ۱۱ افزایش می‌یابد.

۲. ب) تابع هزینه خروج از پنجره: هزینه ایمنی به صورت خروج از هر یک از دو سمت پنجره بازتعریف می‌شود: $c = 1[F < \kappa_{low} \text{ یا } F > \kappa_{high}]$.

۳. ج) اصلاح هدف پاداش: هدف نیرو نزدیک‌ترین نقطه به بهینه آکوستیک در داخل پنجره را هدف می‌گیرد:

$$F_{tgt} = \text{clip}(F_{opt}, \kappa_{low} + 0.4, \kappa_{high} - 0.4) \quad (4-4)$$

در برنامه آموزشی مرحله‌ای این مدل، سقف بالایی $\kappa_{\text{high}} \sim \mathcal{U}[4, 12]$ و عرض پنجره $w \sim \mathcal{U}[1/5, 3]$ با $\kappa_{\text{low}} = \kappa_{\text{high}} - w$ نمونه‌برداری می‌شوند؛ در نتیجه پنجره به طور پیوسته جابه‌جا شده و کف نیرو را به یک قید فعال تبدیل می‌سازد.

۴-۴-۱ تمایز ساختاری دو نسخه سازوکار SBL

به منظور ارزیابی دقیق الگوریتمی و تبیین اثر ساختار قید، سازوکار SBL در دو نسخه مجزا در این پژوهش پیاده‌سازی و ارزیابی شده است:

۱. نسخه اول: SBL تک‌طرفه (سقفی) - One-Sided / Ceiling-Only SBL: در این نسخه،

قید صرفاً به عنوان یک سقف بالایی نیرو تعریف شده و فاقد کران پایینی است ($F \leq \kappa$). از آنجا که تابع پاداش به طور درونی دارای حاشیه هدایت‌کننده به سمت $\kappa - 0.4$ است، ایجنت پیش از برخورد با مرز قید کنترل می‌شود؛ بنابراین این نسخه در یک رژیم قید نیمه‌فعال عمل می‌کند که در آن متغیر دوگان نیاز به صعود سنگین ندارد ($\lambda \approx 0.5$) و تفاوت عملکردی میان روش‌های تنظیم لاگرانژ فشرده است.

۲. نسخه دوم: SBL دوطرفه (پنجره‌ای) - Two-Sided Window SBL: در این نسخه، هر دو

کران بالا و پایین $[\kappa_{\text{low}}, \kappa_{\text{high}}]$ هم‌زمان تحمیل می‌شوند. از آنجا که نقطه بهینه فیزیکی آکوستیک بافت ($F_{\text{opt}} = 7/0$ نیوتن) غالباً در بیرون پنجره تجویزی بالینی قرار می‌گیرد، کشش پاداش و مرزهای قید در تقابل مستقیم قرار می‌گیرند؛ این امر سامانه را به یک رژیم قید کاملاً فعال و الزام‌آور (Strictly Binding Regime, $\lambda \approx 2/25$) سوق می‌دهد که در آن، کارایی واقعی سازوکار هموارسازی SBL در تثبیت آموزش و حذف نوسانات مخرب متغیر دوگان به صورت قاطع اثبات می‌شود.

فصل پنجم

ارزیابی تجربی، نتایج و بحث

در این فصل، پیکربندی تجربی شبیه‌سازی، نتایج به‌دست‌آمده از مقایسه‌ها و مطالعات ابلیشن، بحث و بررسی پیرامون دستاوردها، و در نهایت محدودیت‌ها و افق‌های آینده پژوهش تشریح می‌گردند.

۵-۱ تنظیمات و پیکربندی آزمایش‌ها

ایجننت‌های یادگیری از الگوریتم PPO با پارامتر برش $\epsilon = 0.2$ ، تعداد 10^6 دوره بهینه‌سازی داخلی در هر گام، اندازه مینی‌بچ ۶۴، نرخ یادگیری اکتور $10^{-4} \times 3$ ، نرخ یادگیری کریتیک‌ها 10^{-3} و آستانه برش نرم گرادیان ۵٪ استفاده می‌کنند. ضریب دیسکانت $\gamma = 0.99$ و پارامتر GAE برابر $\lambda_{GAE} = 0.95$ است. ساختار شبکه برای خروجی اکتور و هر یک از کریتیک‌ها شامل یک پرسپترون چندلایه (MLP) با دو لایه پنهان ۱۲۸ نرونی با تابع فعال‌ساز تانژانت هائیربولیک است؛ پارامتر انحراف معیار لگاریتمی اکتور (log-std) قابل یادگیری بوده و در بازه $[-2, 0.5]$ محدود می‌شود. بودجه مجاز نقض ایمنی $d = 0.2$ است. در آزمایش‌های ابلیشن از ۳ بذر تصادفی $\{0, 1, 2\}$ ، مجموع ۴۰ هزار گام زمانی و ۲ هزار گام در هر دوره استفاده شده و در هر مقایسه دقیقاً یک متغیر تغییر داده شده است. مدل اصلی زیروشات به مدت ۸۰ هزار گام در برنامه آموزشی مرحله‌ای^۱ $\kappa \in [3, 12]$ نیوتن آموزش دیده است. کلیه اجراها روی پردازنده مرکزی انجام شده‌اند.

شاخص‌های گزارش‌شده عبارت‌اند از: میانگین و حداکثر نیروی تماس، تعداد نقض‌های ایمنی (تعداد گام‌های با $F > \kappa$)، میانگین شاخص کیفیت تصویر q ، خطای RMSE و بیشینه خطای انحراف جانبی، و دو شاخص پایداری شامل انحراف معیار نقض‌های هر دوره در طول آموزش (train_viol_std) و انحراف معیار مسیر متغیر دوگان لاگرانژ (λ_{std}).

سلب مسئولیت بالینی

تمامی مقادیر آستانه و پنجره‌های نیرو در این پژوهش صرفاً پارامترهای شبیه‌سازی جهت ارزیابی الگوریتمی هستند و نباید به عنوان آستانه‌های اعتبارسنجی شده بالینی برای ایمنی بیمار تفسیر شوند.

^۱Curriculum Learning

۲-۵ مقایسه سیاست‌های HAS-RL با بیس لاین بدون قید


جدول ۱-۵ عملکرد هر دو نگارش چارچوب پیشنهادی (شامل HAS-RL تک‌طرفه و نسخه کران‌دار پنجره‌ای HAS-RL دوطرفه) را در مقایسه با ایجنت استاندارد Vanilla PPO بدون قید (که صرفاً کیفیت تصویر را بدون در نظر گرفتن نیروی وارده بر بافت بیشینه می‌سازد) در سقف ایمنی تنظیمی اپراتور $\kappa = 5$ نیوتن (و پنجره $[\kappa_{low}, \kappa_{high}] = [3, 5]$ نیوتن برای نسخه دوطرفه) نشان می‌دهد.

جدول ۱-۵: مقایسه سیاست‌های HAS-RL (یک‌طرفه و دوطرفه) با بیس لاین بدون قید در سقف $\kappa = 5$ نیوتن (رول‌اوت ۱۰۰ گام)

Model	Mean force (N)	Max force (N)	Image quality	Violations
Baseline (Vanilla PPO)	5.25	5.48	0.90	96
HAS-RL (one-sided)	4.32	4.37	0.80	0
HAS-RL (two-sided)	4.04	4.09	0.77	0

جدول ۱-۵ تقابل بنیادین میان ایمنی بالینی و بیشینه‌سازی بی‌قید پاداش را به روشنی آشکار می‌سازد: ایجنت بیس لاین Vanilla PPO برای ثبت کیفیت تصویر اسمی ۰/۹۰، سقف ایمنی مجاز را کاملاً نادیده گرفته و در ۹۶ گام از ۱۰۰ گام ارزیابی (۹۶٪) با اعمال نیروی فراتر از حد مجاز (میانگین ۵/۲۵ و بیشینه ۵/۴۸ نیوتن) مرتکب نقض ایمنی بیمار شده است. در فرایند تشخیصی سونوگرافی ستون فقرات، چنین فشاری به دلیل خطر آسیب به بافت نرم یا احساس درد شدید بیمار کاملاً مردود است. در نقطه مقابل، هر دو نگارش روش پیشنهادی HAS-RL با پایبندی سخت‌گیرانه و مطلق به حدود تعیین‌شده، **صفر نقض ایمنی** را ثبت کرده‌اند: نسخه تک‌طرفه HAS-RL با میانگین نیروی ۴/۳۲ نیوتن و حداکثر ۴/۳۷ نیوتن (کاملاً ایمن و زیر سقف ۵ نیوتن)، کیفیت تصویر بالای ۰/۸۰ را حاصل نموده و انحنای ستون فقرات با مدل اسکولیوز را با وفاداری جانبی بالا و بدون انحراف دنبال می‌کند. نسخه دوطرفه نیز نیرو را در پنجره $[3, 5]$ با میانگین ۴/۰۴ نیوتن و کیفیت ۰/۷۷ مهار می‌سازد. این نتایج اثبات می‌کنند که سازوکار SBL در نسخه تک‌طرفه به طور کاملاً پایدار عمل کرده و تریدآف واقعی میان ایمنی و کیفیت تصویر را محقق می‌سازد.

شکل ۱-۵ مسیر کامل رقابت هم‌زمان نسخه تک‌طرفه HAS-RL و بیس لاین را در متغیرهای نیرو در برابر سقف، نقض‌های تجمعی، کیفیت تصویر و رهگیری خط مرکزی ستون فقرات نشان می‌دهد.



شکل ۵-۱: مقایسه هم‌زمان رفتار نسخه تک‌طرفه HAS-RL با بیس‌لاین بدون قید در سقف $\kappa = 5$ نیوتن. بالا-چپ: نیروی تماس در برابر سقف؛ بیس‌لاین (قرمز) پیوسته بالاتر از سقف حرکت می‌کند و روش پیشنهادی (سبز) زیر سقف باقی می‌ماند. بالا-راست: نقض‌های تجمعی (بیس‌لاین به ۹۶ می‌رسد و روش ما در صفر است). پایین-چپ: رد کیفیت تصویر. پایین-راست: رهگیری دقیق انحنای ستون فقرات.

۳-۵ ارزیابی ایمنی زیروشات با سقف متغیر اپراتور

policy واحد آموزش‌دیده بر روی برنامه آموزشی مرحله‌ای $\kappa \in [3, 12]$ نیوتن، بدون هیچ‌گونه آموزش بیشتر یا اصلاح پارامتر، در هفت سقف تنظیمی مختلف مورد ارزیابی قرار گرفت (جدول ۵-۲). سه نتیجه کلیدی از این ارزیابی حاصل می‌شود:

۱. الف) افزایش یکنواخت نیرو با سقف اپراتور: نیروی تماس با افزایش κ از $1/13$ نیوتن در $\kappa = 3$ به $7/97$ نیوتن در $\kappa = 12$ می‌رسد که نشان‌دهنده دامنه تغییرات $6/84$ نیوتن است؛ این رفتار اثبات می‌کند policy مقدار تنظیمی اپراتور را درک کرده و از آن تبعیت می‌نماید.

۲. ب) صفر بودن مطلق نقض‌ها: در تمام سقف‌های آزمون، تعداد نقض‌های ایمنی صفر بوده و هیچ رول‌اوتی از سقف فعال خود تجاوز نکرده است.


۳. ج) تطابق کیفیت تصویر با فیزیک آکوستیک: کیفیت تصویر در حوالی $10^\circ \approx \kappa$ نیوتن (جایی که نیروی ایمن به نقطه بهینه $F_{opt} = 7$ نیوتن نزدیک می‌شود) به اوج 76% می‌رسد و در سقف ۱۲ به دلیل عبور نقطه هدف از بهینه، اندکی کاهش می‌یابد.

جدول ۵-۲: ارزیابی زیروشات در سطوح مختلف سقف ایمنی اپراتور با policy واحد (بدون بازآموزی)


κ (N)	Mean force (N)	Max force (N)	Violations	Ceiling breach	Image quality
3.0	1.13	1.67	0	no	0.11
4.0	2.50	2.66	0	no	0.26
5.0	3.61	3.78	0	no	0.48
6.0	4.53	4.70	0	no	0.58
8.0	5.98	6.26	0	no	0.73
10.0	7.13	7.47	0	no	0.76
12.0	7.97	8.45	0	no	0.66

Force range: $\kappa = 3 \rightarrow 12$: +6.84 N; Total violations: 0

شکل ۵-۲ (الف) تغییرات نیرو و کیفیت را در برابر κ نشان می‌دهد؛ همچنین شکل ۵-۲ (ب) پاسخ بلادرنگ policy واحد به تغییر آنلاین حد فشار در حین اسکن ($11 \rightarrow 4 \rightarrow 9$ نیوتن) را به تصویر می‌کشد که در آن نیرو بدون عبور از سقف، تغییرات را دنبال می‌کند.



(ب) تغییر پیوسته سقف در میانه اسکن ($9 \rightarrow 4 \rightarrow 11$ نیوتن)



(آ) تغییرات نیرو و کیفیت در برابر سقف κ

شکل ۵-۲: رفتار ایمنی زیروشات policy واحد. policy بدون بازآموزی نیروی تماس را با κ تطبیق داده و هرگز از سقف فعال عبور نمی‌کند.

۴-۵ تحلیل ابلیشن الف: اثر پیش‌نگری بر رهگیری جانبی

برای ارزیابی اثر مؤلفه‌های پیش‌نگری در بردار state، مدل در دو حالت فعال بودن این مؤلفه‌ها و مقداردهی آن‌ها با صفر، روی ۳ بذر تصادفی آموزش داده شد و خطای رهگیری ارزیابی گردید (جدول ۵-۳).

حضور مؤلفه‌های پیش‌نگری، خطای رهگیری RMSE^۲ را ۲۸ درصد (از ۰/۰۸۴ به ۰/۰۶۱) و بیشینه خطای انحراف را نیز ۲۸ درصد (از ۰/۱۳۷ به ۰/۰۹۹) کاهش داده است. در ارزیابی معیار تأخیر فاز با تابع

Root Mean Square Error^۲

جدول ۳-۵: تحلیل ابلیشن الف: اثر مؤلفه‌های پیش‌نگری بر خطای رهگیری جانبی (میانگین $\pm$ انحراف معیار روی ۳ بذر)

Look-ahead	RMS lateral error	Max lateral error
On (ours)	0.061 ± 0.060	0.099 ± 0.092
Off	0.084 ± 0.048	0.137 ± 0.068
Lateral tracking error reduction: 28% across both metrics		

همبستگی متقابل، به دلیل نویز بالا در این بودجه محاسباتی، انحراف معیار بین بذرها از مقدار میانگین فراتر رفت ($24/3 \pm 16/7$ - در برابر $28/5 \pm 6/3$ - گام)؛ بنابراین با شفافیت علمی، صرفاً به گزارش کاهش قطعی خطای رهگیری اکتفا می‌شود.

۵-۵ تحلیل ابلیشن ب: ارزیابی روش‌های متغیر دوگان در نسخه

تک‌طرفه (سقفی) SBL


در این آزمایش، روش‌های مختلف به‌روزرسانی ضریب لاگرانژ در نسخه تک‌طرفه (سقفی) چارچوب مورد ارزیابی قرار می‌گیرند؛ نسخه‌ای که صرفاً دارای یک سقف بالایی نیرو (κ) بوده و فاقد کران پایینی است. با تغییر انحصاری شیوه به‌روزرسانی ضریب لاگرانژ و یکسان نگه‌داشتن کلیه شرایط تجربی روی ۳ بذر تصادفی، نتایج جدول ۴-۵ و شکل ۳-۵ حاصل شد.

جدول ۴-۵: تحلیل ابلیشن ب: مقایسه روش‌های تنظیم متغیر دوگان در نسخه تک‌طرفه سقفی (میانگین $\pm$ انحراف معیار روی ۳ بذر)

Mode	Eval violations	Image quality	train_viol_std	λ_{std}
dual (PPO-Lagrangian)	0.0 ± 0.0	0.576 ± 0.138	16.66 ± 10.24	0.29 ± 0.10
exp3_raw (online bandit)	0.0 ± 0.0	0.492 ± 0.142	13.51 ± 12.76	1.43 ± 0.50
sbl (ours)	0.0 ± 0.0	0.603 ± 0.150	11.99 ± 12.44	0.42 ± 0.02

چهار نکته اساسی از این آزمایش استخراج می‌گردد:

- الف) رعایت کامل ایمنی در هر سه روش: تمامی روش‌ها در فاز ارزیابی به صفر نقض قید دست می‌یابند. بخشی از این رفتار ناشی از آن است که جمله آگاه از بودجه در تابع پاداش، نیرو را به سمت $\kappa - 0/4$ هدایت می‌کند؛ در نتیجه در این نسخه سقفی، قید به ندرت به صورت بحرانی فعال می‌شود و سیستم در یک رژیم قید نیمه‌فعال سیر می‌کند.



شکل ۵-۳: پایداری متغیر دوگان در طول آموزش (بذر صفر). چپ: تغییرات ضریب فعال λ ؛ باندیت خام (قرمز) میان بازوها دچار جهش‌های شدید است، صعود دوگان (آبی) بسیار کند بالا می‌رود و روش پیشنهادی SBL (سبز) روندی کاملاً نرم دارد. راست: نوسانات نقض‌های هر دوره.

۲. (ب) حاشیه برتری محدود در نسخه تک‌طرفه: روش SBL به میانگین کیفیت تصویر 0.60 ± 0.03 دست می‌یابد که بالاتر از صعود دوگان (0.576 ± 0.004) و باندیت خام (0.492 ± 0.004) است. با این حال، همان‌طور که با صداقت علمی باید اذعان داشت، اختلاف کیفی 0.27 ± 0.004 در این نسخه درون دامنه انحراف معیار بذرها (0.150 ± 0.004) قرار می‌گیرد و به دلیل نبود کران پایین، تفوق الگوریتمی SBL هنوز به اوج تمایز خود نرسیده است.

۳. (ج) ناپایداری شدید باندیت خام: انحراف معیار متغیر دوگان در باندیت خام برابر 0.50 ± 0.43 است که تقریباً ۳ برابر روش پیشنهادی ماست؛ این جهش‌های ناگهانی میان بازوهای گسسته، پایداری یادگیری گرادیان را تخریب کرده و کیفیت تصویر را به شدت افت می‌دهد.

۴. (د) پایداری و تکرارپذیری بالای روش پیشنهادی: روش پیشنهادی کمترین واریانس نقض‌های آموزش ($11/99$) و مسیر فوق‌العاده پایدار و تکرارپذیر بین بذرها (0.42 ± 0.02) را ثبت می‌کند که نشان می‌دهد هموارسازی EMA بر امید ریاضی باندیت، رفتار ناپایدار باندیت خام را به طور کامل مهار ساخته است.


۵-۶ پنجره دوطرفه اپراتور: بهره‌گیری کامل از دامنه مجاز نیرو

policy واحد آموزش‌دیده در برنامه آموزشی مرحله‌ای پنجره دوطرفه، در ۶ پنجره تشخیصی ارزیابی شد (جدول ۵-۵ و شکل ۵-۴).

سه نتیجه کلیدی از این آزمایش حاصل می‌شود:

جدول ۵-۵: ارزیابی پنجره دوطرفه اپراتور با policy واحد و بدون بازآموزی (100% درصد حضور درون پنجره)

Window $[\kappa_{low}, \kappa_{high}]$ (N)	Mean force	Min force	Max force	In-window	Image quality
[2.5, 4.0]	3.26	3.23	3.33	100%	0.67
[3.0, 5.0]	4.04	4.01	4.08	100%	0.77
[4.0, 6.0]	5.02	4.99	5.09	100%	0.88
[5.0, 8.0]	6.50	6.41	7.17	100%	0.99
[7.0, 10.0]	8.36	8.35	8.38	100%	0.94
[9.0, 12.0]	10.22	9.90	10.26	100%	0.74



شکل ۵-۴: رفتار policy در پنجره‌های دوطرفه مختلف اپراتور. نوار خاکستری پنجره مجاز $[\kappa_{low}, \kappa_{high}]$ و منحنی سبز نیروی تماس اعمالی را نشان می‌دهد که کاملاً درون بازه حرکت می‌کند.

۱. الف) پایبندی کامل به بازه: در تمامی پنجره‌ها، میزان حضور 100% درصد و تعداد نقض خروج از پنجره صفر است و حداقل نیرو همواره بزرگ‌تر از κ_{low} می‌ماند.

۲. ب) استفاده کامل از ظرفیت مجاز: میانگین نیرو با موقعیت پنجره بالا می‌رود؛ به طوری که در پنجره $[9, 12]$ نیوتن، میانگین نیرو به 10.22 نیوتن می‌رسد، در حالی که در مدل سقف یک‌طرفه با $\kappa = 12$ نیرو روی 7.97 نیوتن متوقف شده بود. بدین ترتیب حدود $3/5$ نیوتن از ظرفیت مجاز بازیابی می‌شود.

۳. ج) تطابق دقیق کیفیت با فیزیک صوت: کیفیت تصویر در پنجره $[5, 8]$ نیوتن که نقطه بهینه $F_{opt} = 7$ نیوتن را در بر می‌گیرد، به اوج خود (99%) می‌رسد و با فاصله گرفتن پنجره کاهش

می‌یابد.

در پنجره دوطرفه، قید ایمنی وارد رژیم کاملاً فعال و الزام‌آور می‌شود؛ زیرا بر خلاف نسخه تک‌طرفه (که در آن متغیر دوگان روی $\lambda \approx 0.5$ متوقف می‌شد)، در پنجره دوطرفه ضریب لاگرانژ به $\lambda \approx 2/25$ صعود می‌کند. این شرایط، آزمونی واقعی و سخت‌گیرانه برای سنجش کارایی روش‌های تنظیم ضریب لاگرانژ پدید می‌آورد.

۷-۵ تحلیل ابلیشن ج: ارزیابی روش‌های متغیر دوگان در نسخه

دوطرفه (پنجره‌ای) SBL

همان‌طور که در بخش ۴-۴-۱ و تحلیل ابلیشن ب (بخش ۵-۵) مطرح شد، در نسخه تک‌طرفه (سقفی) SBL، به دلیل هم‌پوشانی جاذب پاداش با حاشیه ایمنی، قید به صورت نیمه‌فعال باقی می‌ماند و برتری روش پیشنهادی نسبت به صعود دوگان اندک (0.603 در برابر 0.576) و درون بازه انحراف معیار بذرها بود. اما در نسخه دوطرفه (پنجره‌ای)، از آنجا که بهینه فیزیکی آکوستیک ($F_{\text{opt}} = 7/0$ نیوتن) غالباً بیرون از پنجره تجویزی بالینی است، تضاد ساختاری میان پاداش و ایمنی رخ می‌دهد و قید به طور کامل فعال می‌گردد (Strictly Binding Regime). با تکرار آزمایش مقایسه‌ای متغیر دوگان در این رژیم دوطرفه روی ۳ بذر تصادفی، نتایج جدول ۶-۵ حاصل گردید.

جدول ۶-۵: مقایسه روش‌های تنظیم ضریب لاگرانژ در نسخه دوطرفه (پنجره‌ای) SBL (میانگین $\pm$ انحراف معیار روی ۳ بذر)

Mode	Eval violations	Image quality	train_viol_std	λ_{std}
dual (PPO-Lagrangian)	0.0 ± 0.0	0.677 ± 0.086	21.07 ± 6.49	0.26 ± 0.09
exp3_raw (online bandit)	0.0 ± 0.0	0.594 ± 0.018	21.76 ± 7.23	1.53 ± 0.15
sbl (ours)	0.0 ± 0.0	0.715 ± 0.011	22.90 ± 7.01	0.45 ± 0.00

در این رژیم مقیدساز دوطرفه، تمایز و برتری نسخه پنجره‌ای SBL به وضوح آشکار می‌شود:

- الف) ارتقای معنادر کیفیت تصویر: روش پیشنهادی SBL با ثبت میانگین کیفیت 0.715 برتری آشکاری ($+0.38$) نسبت به صعود دوگان (0.677) و باندیت خام (0.594) نشان می‌دهد.
- ب) تکرارپذیری و پایداری حدود ۸ برابری: انحراف معیار کیفیت تصویر در نسخه دوطرفه SBL تنها ± 0.11 است، در حالی که این پراکندگی در صعود دوگان به ± 0.86 می‌رسد. این امر

اثبات می‌کند که هموارسازی میانگین متحرک و تلفیق امید ریاضی در SBL، حساسیت شدید به بذره‌های اولیه آموزش را خنثی کرده و عملکردی فوق‌العاده باثبات ارائه می‌دهد.

• (ج) مهار ناپایداری باندیت خام: باندیت خام آنالین با جهش‌های گسسته و انحراف بسیار بالای ضریب ($\lambda_{std} = 1/53 \pm 0/15$) دچار افت محسوس کیفیت تصویر ($0/594$) می‌شود، در حالی که SBL با تثبیت λ_{std} روی $0/45$ از این تلاطم جلوگیری می‌کند.

۵-۸ بحث و بررسی

الف) چرایی برتری یادگیری تقویتی ایمن بر برش مکانیکی^۳: یک پرسش طبیعی در طراحی سامانه‌های ایمنی آن است که چرا به جای یادگیری تقویتی ایمن، صرفاً یک اشباع‌کننده یا برش مکانیکی بر خروجی action ربات اعمال نمی‌شود؟ چنانچه یک ایجنت عادی در پشت یک برش سخت‌افزاری قرار گیرد، میل به بیشینه‌سازی پاداش سبب می‌شود پیوسته دستوراتی فراتر از سقف صادر کند. در سیستم واقعی، این تقابل مداوم با بلوک ایمنی سطح پایین موجب اشباع عملگرها، حرکات تکانه‌ای و فعال‌سازی ترمزهای اضطراری فیزیکی می‌شود. در مقابل، یادگیری تقویتی ایمن قید را به صورت مفهومی درون policy آموزش می‌دهد؛ در نتیجه ایجنت رویکردی نرم و هوشمندانه اتخاذ کرده و پروب را بدون هیچ ضربه‌ای بر لبه مجاز نگاه می‌دارد. علاوه بر این، درونی‌سازی قید، قابلیت تغییر آنالین سقف به صورت زیروشات را ممکن می‌سازد.

ب) تمایز ساختاری و مقایسه‌ای دو نسخه SBL: در این پژوهش دو نسخه از SBL ارزیابی شد:

۱. در نسخه تک‌طرفه (سقفی)، هدف پاداش نیرو را پیش از رسیدن به مرز جذب می‌کند ($F_{tgt} \leq$) $0/4 - k_i$ ؛ در نتیجه قید کمتر فعال می‌شود ($\lambda \approx 0/5$) و تفاوت روش‌ها در کیفیت ($0/603$) در برابر $0/576$) کوچک و در محدوده انحراف معیار بذرها باقی می‌ماند که ممکن است تفاوت چشمگیری به نظر نرسد.

۲. در نسخه دو‌طرفه (پنجره‌ای)، قید ایمنی به طور کامل الزام‌آور و فعال است ($\lambda \approx 2/25$). در این محیط سخت‌گیرانه، مزیت حقیقی SBL آشکار می‌شود: نه تنها کیفیت تصویر بالاتری ($0/715$ در برابر $0/677$) ارائه می‌دهد، بلکه تکرارپذیری آن میان بذره‌های تصادفی حدود ۸ برابر بهتر از صعود دوگان است ($0/11 \pm$ در برابر $0/86 \pm$).

ج) فریبندگی ظاهری Vanilla PPO در برابر واقعیت نقض‌های بالینی: یکی از مشاهدات مهم در تحلیل بیس‌لاین‌ها آن است که الگوریتم بدون قید PPO ممکن است در نگاه اول با کیفیت تصویر ۹۰٪ سالم و موفق به نظر برسد؛ اما این یک سراب خطرناک است. این الگوریتم برای دستیابی به این کیفیت، در ۹۵ گام از ۱۰۰ گام ارزیابی (۹۵٪) قید مجاز ایمنی بیمار را با نیروی بیش از حد ۵/۴۸ نیوتن زیر پا می‌گذارد. در یک فرایند تشخیصی بالینی، وارد کردن نیروی فراتر از آستانه درد یا آسیب بیمار به بهای افزایش وضوح تصویر، کاملاً غیرقابل قبول است. روش پیشنهادی ما اثبات می‌کند که با تلفیق یادگیری تقویتی ایمن و سازوکار SBL، می‌توان بالاترین کیفیت دست‌یافتنی در مرز مجاز (۰/۷۱۵) را همراه با تضمین مطلق صفر نقض ایمنی به دست آورد.

۹-۵ محدودیت‌های پژوهش

نتایج این پژوهش در یک شبیه‌ساز تک‌بعدی حاصل شده‌اند، نه بر روی ربات فیزیکی، داده‌های تصویر واقعی اولتراسوند یا موتورهای جراحی سه‌بعدی پیشرفته (نظیر سونوژیم [۱۲])؛ مدل‌های کیفیت تصویر و نیرو تقریبی هستند، نه مکانیک کالبره‌شده بافت بیولوژیکی. تعداد بذره‌های تصادفی در تحلیل‌های ابلیشن به ۳ بذر محدود بوده است؛ این تعداد جهت نشان دادن ناپایداری باندیت خام و کاهش خطای پیش‌نگری کافی است، اما برای فواصل اطمینان فشرده روی تفاوت‌های کوچک کیفیت نیازمند داده‌های بیشتر است. هندسه ستون فقرات با یک سینوس با دامنه ثابت مدل شده و حرکات خارج از صفحه پروب یا تغییر شکل بافت لحاظ نشده‌اند. همچنین رهگیری پیش‌بینانه متکی بر دسترسی به خطای گام‌های آینده است که در عمل باید از طریق اسکن مقدماتی یا ثبت با اطلس‌های تشریحی تأمین گردد.

۱۰-۵ نتیجه‌گیری و افق‌های آینده

چارچوب پیشنهادی HAS-RL توانست آستانه ایمنی نیروی پروب سونوگرافی را از یک پارامتر منجمد در زمان آموزش به یک فرمان بلادرنگ در زمان استقرار تبدیل کند: یک policy واحد طیفی پیوسته از سقف‌های ایمنی را پوشش داده و بدون هیچ بازآموزی و با صفر نقض قید، رفتار خود را با حد مجاز آنلاین تعیین‌شده توسط اپراتور تطبیق می‌دهد. همچنین سازوکار SBL پایداری باندیت‌های آنلاین را تضمین کرده و بالاترین کیفیت تصویر را در ایمنی برابر به دست آورد، و پیش‌نگری خطا دقت رهگیری را ۲۸ درصد بهبود بخشید.

مسیرهای طبیعی برای ادامه این پژوهش شامل آزمایش بر روی توابع پاداش چالش برانگیزتر، پیاده‌سازی بر روی بازوی رباتیک فیزیکی همکار و ارزیابی با تصاویر واقعی سونوگرافی خواهد بود.

منابع و مراجع

- [1] Duan, Anqing, Yang, Chenguang, Zhao, Jingyuan, Huo, Shengzeng, Zhou, Peng, Ma, Wanyu, Zheng, Yongping, and Navarro-Alarcon, David. Safe learning by constraint-aware policy optimization for robotic ultrasound imaging. *IEEE Transactions on Automation Science and Engineering*, 22:2349–2360, 2025.
- [2] Chemingui, Yassine, Deshwal, Aryan, Fern, Alan, Nguyen-Tang, Thanh, and Doppa, Janardhan Rao. Online optimization for offline safe reinforcement learning, 2025.
- [3] Altman, Eitan. *Constrained Markov Decision Processes*. Chapman & Hall/CRC, 1999.
- [4] Achiam, Joshua, Held, David, Tamar, Aviv, and Abbeel, Pieter. Constrained policy optimization. in Precup, Doina and Teh, Yee Whye, eds. , *Proceedings of the 34th International Conference on Machine Learning*, vol. 70 of *Proceedings of Machine Learning Research*, pp. 22–31. PMLR, 06–11 Aug 2017.
- [5] Ray, Alex, Achiam, Joshua, and Amodei, Dario. Benchmarking safe exploration in deep reinforcement learning. tech. rep., OpenAI, 2019.
- [6] Tessler, Chen, Mankowitz, Daniel J., and Mannor, Shie. Reward constrained policy optimization, 2018.
- [7] Stooke, Adam, Achiam, Joshua, and Abbeel, Pieter. Responsive safety in reinforcement learning by PID lagrangian methods. in III, Hal Daumé and Singh, Aarti, eds. , *Proceedings of the 37th International Conference on Machine Learning*, vol. 119 of *Proceedings of Machine Learning Research*, pp. 9133–9143. PMLR, 13–18 Jul 2020.

- [8] Auer, Peter, Cesa-Bianchi, Nicolò, Freund, Yoav, and Schapire, Robert E. The non-stochastic multiarmed bandit problem. *SIAM Journal on Computing*, 32(1):48–77, January 2002.
- [9] Hase, Hannes, Azampour, Mohammad Farid, Tirindelli, Maria, Paschali, Magdalini, Simson, Walter, Fatemizadeh, Emad, and Navab, Nassir. Ultrasound-guided robotic navigation with deep reinforcement learning. in *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, p. 5534–5541. IEEE, October 2020.
- [10] Schulman, John, Wolski, Filip, Dhariwal, Prafulla, Radford, Alec, and Klimov, Oleg. Proximal policy optimization algorithms, 2017.
- [11] Schulman, John, Moritz, Philipp, Levine, Sergey, Jordan, Michael, and Abbeel, Pieter. High-dimensional continuous control using generalized advantage estimation, 2018.
- [12] Ao, Yunke, Moghani, Masoud, Mittal, Mayank, Prajapat, Manish, Wu, Luohong, Giraud, Frederic, Carrillo, Fabio, Krause, Andreas, and Färnstahl, Philipp. Sonogym: High performance simulation for challenging surgical tasks with robotic ultrasound. in *Advances in Neural Information Processing Systems 38, NeurIPS 2025*, p. 45013–45040. Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2025.

پیوست: جدول فرایارامترها و مشخصات پیاده‌سازی

در این پیوست، کلیه فرایارامترهای آموزشی، مشخصات ساختاری شبکه‌های عصبی و مقادیر متغیرهای فیزیکی شبیه‌ساز که در پیاده‌سازی چارچوب HAS-RL مورد استفاده قرار گرفته‌اند، به منظور بازتولیدپذیری دقیق نتایج خلاصه شده‌اند.

الف - معماری شبکه‌های عصبی

policy (اکتور) و دو شبکه کریتیک ارزش به صورت شبکه‌های پیش‌خور چندلایه^۴ با ساختار زیر پیاده‌سازی شده‌اند:

- الف) تعداد لایه‌های پنهان: ۲ لایه با ۱۲۸ نرون در هر لایه.
- ب) تابع فعال‌ساز: تانژانت هایپربولیک^۵ در لایه‌های پنهان.
- ج) بردار خروجی اکتور: میانگین بردار action در بازه $[-1, 1]$ به صورت خروجی خطی، و پارامتر انحراف معیار لگاریتمی (log-std) قابل یادگیری که در بازه $[-2/0, 0/5]$ محدود می‌شود.
- د) بردار ورودی شبکه: بردار مشاهده ۱۰ بعدی در حالت سقف یک‌طرفه و ۱۱ بعدی در حالت

پنجره دو طرفه.

Multilayer Perceptron (MLP)^۴

Hyperbolic Tangent (Tanh)^۵

ب - جدول جامع فرایارامترها

جدول ۷: فرایارامترهای یادگیری تقویتی، باندیت و شبیه‌ساز در چارچوب HAS-RL

مؤلفه	فرایارامتر	مقدار
PPO	پارامتر برش نسبت چگالی (ϵ)	0.2
	نرخ یادگیری اکتور	3×10^{-4}
	نرخ یادگیری کریٹیک‌ها	$10^{-3} \times 10^{-3}$
	اندازه مینی‌بچ (Minibatch size)	64
	تعداد اپوک‌های بهینه‌سازی در هر گام	10
GAE	آستانه برش گرادیان (Gradient clip)	0.5
	ضریب دیسکانت زمانی (γ)	0.99
	پارامتر واپاشی اثر GAE (λ_{GAE})	0.95
SBL و ایمنی	تعداد بازوهای گسسته باندیت (K)	۵ بازو در بازه $[0, 5]$
	نرخ یادگیری باندیت (η)	0.05
	ضریب هموارسازی نمایی (τ)	0.05
	بودجه مجاز نقض قید هر گام (d)	0.02
شبیه‌ساز و پاداش	طول افق زمانی هر اپیزود (T)	۱۰۰ گام
	حداکثر گام تغییر نیرو در هر مرحله	0.7 نیوتن
	نیروی بهینه آکوستیک (F_{opt})	7.0 نیوتن
	حداقل نیروی اتصال اولیه (F_{min})	1.0 نیوتن
	دامنه انحنای ستون فقرات (A)	0.7

کلیه آزمایش‌ها با استفاده از کتابخانه PyTorch بر روی پردازنده مرکزی اجرا شده و متغیرهای تصادفی با بذره‌ای معین مقداردهی اولیه شده‌اند.

واژه‌نامه‌ی فارسی به انگلیسی

Baseline بیس لاین	آ
پ	آزادسازی لاگرانژ . . Lagrangian Relaxation
Dense Reward پاداش متراکم	ا
Policy policy	ابلیشن (تحلیل تفکیکی) . . . Ablation Study
Acoustic Window پنجره آکوستیک	آدونتیج (مزیت) . . . Advantage
Two-Sided Window پنجره دوطرفه	اکتور (بازیگر) . . . Actor
Ultrasound Probe پروب سونوگرافی	Action action
ت	امید ریاضی Expectation
Value Function تابع ارزش	ایمنی زیروشات Zero-Shot Safety
B-mode Ultrasound . B حالت تصویربرداری	اولتراسوند رباتیک Robotic Ultrasound
ج	ب
Time-Gain جبران بهره با زمان	الگوریتم باندیت (MAB) Multi-Armed
Compensation	Bandit
	برآورد مزیت تعمیم‌یافته (GAE) Generalized
	Advantage Estimation

Low-Pass Filter فیلتر پایین‌گذر

Acoustic Coupling . جفت‌شدگی آکوستیک

ق

خ

Binding Constraint . . (Binding) قید فعال

Lateral Error خطای جانبی

ک

ر

Critic کریتیک (منتقد)

Anticipatory Tracking . رهگیری پیش‌بینانه

Impedance Control کنترل امپدانس

Rollout رول‌اوت (پیمایش مسیر)

Preview Control کنترل پیش‌نگر

س

ل

Smoothed . (SBL) لاگرانژ باندیتی هموارشده

Acoustic Shadow سایه آکوستیک

Bandit-Lagrangian

Dual Ascent صعود دوگان

م

ش

Dual Variable متغیر دوگان

Operator شرطی‌سازی بر اپراتور

Minibatch مینی‌بچ

Conditioning

Exponential (EMA) میانگین متحرک نمایی

ض

Moving Average

ن

Discount Factor ضریب دیسکانت

Trust Region ناحیه اعتماد

Lagrangian Multiplier ضریب لاگرانژ

Speckle Noise نویز اسپکل

ف

ی

فرایند تصمیم‌گیری مارکوف مقید (CMDP)

Safe Reinforcement یادگیری تقویتی ایمن

Constrained MDP

Learning

Online Learning یادگیری آنلاین

Offline Learning یادگیری آفلاین

Curriculum(Curriculum) یادگیری مرحله‌ای

Learning

واژه‌نامه‌ی انگلیسی به فارسی

A	فرایند تصمیم‌گیری مارکوف مقید (CMDP)
Ablation Study . . مطالعه ابلیشن (تفکیکی)	Constrained MDP
Acoustic Coupling اتصال آکوستیک	Cost Critic کریتیک هزینه
Action Space فضای action	Curriculum Learning . . . یادگیری مرحله‌ای
Actor-Critic معماری اکتور-کریتیک	D
Architecture	Dense Reward پاداش متراکم
Advantage Function . . تابع ادونتیج (مزیت)	Discount Factor ضریب دیسکانت
Anticipatory Tracking . رهگیری پیش‌بینانه	Dual Ascent صعود دوگان
B	Dual Variable متغیر دوگان
Baseline بیس‌لاین	E
Binding Constraint . . قید فعال (Binding)	End-Effector . عملگر انتهایی (مجری نهایی)
B-mode Ultrasound سونوگرافی حالت B	Exponential (EMA) میانگین متحرک نمایی
Budget-Aware Target . . هدف آگاه از بودجه	Moving Average
C	G
Clipping Objective . . تابع هدف برش‌خورده	

برآورد مزیت تعمیم‌یافته (GAE) Generalized Advantage Estimation	یادگیری تقویتی آفلاین Offline Reinforcement Learning
H	گرادیان policy آنلاین Online Policy Gradient
ظرفیت استفاده‌نشده (هد روم) . . Headroom Gap	شرطی‌سازی بر تنظیمات اپراتور . . . Operator Conditioning
پربازتاب (هایپراکوژنیک) Hyperechoic	P
I	Policy policy
کنترل امپدانس Impedance Control	کنترل پیش‌نگر Preview Control
وزن‌دهی اهمیت . . . Importance Weighting	بهینه‌سازی policy نزدیک (PPO) . Proximal Policy Optimization
L	R
ضریب لاگرانژ Lagrangian Multiplier	نویز اسپکل ریلی Rayleigh Speckle
آزادسازی لاگرانژ . . . Lagrangian Relaxation	کران‌های پشیمانی Regret Bounds
خطای انحراف جانبی Lateral Error	کریتیک پاداش Reward Critic
فیلتر پایین‌گذر Low-Pass Filter	رول‌اوت (پیمایش مسیر) Rollout
M	S
مینی‌بچ Minibatch	یادگیری تقویتی ایمن . Safe Reinforcement Learning
الگوریتم باندیت (MAB) Multi-Armed Bandit	لاگرانژ باندیتی هموارشده (SBL) . Smoothed Bandit-Lagrangian
N	T
ناایستایی Non-Stationarity	
O	

Time-Gain (TGC) جبران بهره با زمان	Two-Sided Window پنجره دوطرفه
Compensation	Z
Trust Region ناحیه اعتماد	
Twin Critics دو کریتیک مجزا	Zero-Shot Safety ایمنی زیروشات

Abstract

Robot-assisted ultrasound (US) imaging offers substantial clinical benefits by standardizing diagnostic examinations and mitigating work-related musculoskeletal disorders (WRMSDs) among sonographers. However, any assistive robotic system physically interacting with a patient must strictly adhere to clinician-supervised force safety constraints that vary according to tissue characteristics, patient condition, and clinical preferences. Prior safe reinforcement learning (RL) methods for robotic US train a policy against a single fixed force threshold, meaning that any clinical adjustment to the tolerated force requires retraining from scratch; recent bandit-based safe-RL multiplier techniques, in turn, were developed exclusively for offline settings and inject destabilizing non-stationarity when deployed directly into an online policy-gradient loop. We present HAS-RL, an assistive clinical framework with four coupled contributions. (i) Operator-conditioned zero-shot safety: instead of a fixed maximum force, the clinician’s runtime safety threshold is incorporated directly into the observation space, and a single policy is trained across a randomized curriculum. The resulting policy compliantly adapts its contact force to the clinician’s chosen threshold at deployment with zero retraining, seamlessly tracking online adjustments to the force limit during scanning without breaching safety bounds. (ii) The Smoothed Bandit-Lagrangian (SBL), which drives an EXP3 multiplier bandit while applying an exponential-moving-average (EMA) of the multiplier expectation to the policy update. Across three random seeds, SBL achieves the highest mean image quality (0.603) and superior training stability (lowest per-epoch violation variance and a tightly bounded multiplier trajectory, $\lambda_{\text{std}} = 0.42 \pm 0.02$) while maintaining the zero-violation safety of standard dual ascent. (iii) Anticipatory tracking via a short look-ahead of future anatomical curvature errors (e_{+5}, e_{+15}), which reduces root-mean-square lateral tracking error by 28% ($0.084 \rightarrow 0.061$). (iv) Two-sided acoustic-window safety: ultrasound force safety is formulated not merely as a one-sided ceiling, but as a clinician-specified diagnostic window $[\kappa_{\text{low}}, \kappa_{\text{high}}]$ ensuring sufficient acoustic contact while preventing excessive pressure. We provide a lightweight, fully reproducible simulation environment running

entirely on standard CPUs to facilitate clinical research verification.

Key Words:

Safe Reinforcement Learning, Robotic Ultrasound, Constrained Markov Decision Process, Lagrangian Relaxation, Operator Conditioning, Zero-Shot Safety



**Amirkabir University of Technology
(Tehran Polytechnic)**

Faculty of Mathematics and Computer Science

B. Sc. Project

HAS-RL: Human-Adaptive Safe Reinforcement Learning for Clinician-Configured Force Safety in Robotic Ultrasound Spinal Scanning

By

Mohammad Hadi Niknam

Supervisor

Dr. Rouhollah Ahmadian

Examiner

Dr. Mehdi Ghatee

Summer 2026