

HAS-RL: Human-Adaptive Safe Reinforcement Learning for Clinician-Configured Force Safety in Robotic Ultrasound Spinal Scanning

یادگیری تقویتی ایمن با تنظیم نیرو توسط اپراتور

Mohammad hadi Niknam

۱۰ مهر ۱۴۰۵

اولتراسونوگرافی (US) ارزان، قابل حمل و بدون تشعشع است؛ اما ارزش تشخیصی آن به شدت به مهارت مکانیکی اپراتور وابسته است.

پروب باید نسبت به آناتومی هدف، عمود و متمرکز نگه داشته شود و با نیروی کافی فشرده شود تا کوپلینگ آکوستیک از طریق پوست برقرار شود، اما نه آنقدر زیاد که به بیمار آسیب بزند.

Assisting this skill with a robot is attractive for throughput and standardization.

اما تماس فیزیکی انسان-ربات، ایمنی را به یک الزام اولیه و غیرقابل مذاکره تبدیل می‌کند، نه یک هدف نرم.

یادگیری تقویتی برای یادگیری سیاست نیرو/موقعیت مناسب است، زیرا کوپلینگ بین نیروی اعمالی و کیفیت تصویر غیرخطی است و مدل بسته‌ای ندارد.

اما یک عامل پیشینه‌کننده پاداش، به راحتی از این حقیقت سوءاستفاده می‌کند که نیروی بیشتر یعنی کوپلینگ بهتر و در نتیجه کیفیت تصویر بالاتر؛ پس تا وقتی صریحاً مقید نشود، نیرو را دلخواه بالا می‌برد.

This is the core tension that safe RL must resolve
for medical robotics.



WIKIPEDIA
The Free Encyclopedia

 Search Wikipedia

[Donate](#) [Create account](#) [Log in](#) ...

[38 languages](#)

Contents [hide](#)

(Top)

[Principles](#)

[Exploration](#)

> [Algorithms for control learning](#)

[Theory](#)

[Research](#)

> [Comparison of key algorithms](#)

[Statistical comparison of reinforcement learning algorithms](#)

[See also](#)

[References](#)

[Further reading](#)

[External links](#)

Reinforcement learning

[Article](#) [Talk](#)

[Read](#) [Edit](#) [View history](#) [Tools](#) [▼](#)


From Wikipedia, the free encyclopedia

For reinforcement learning in psychology, see [Reinforcement](#) and [Operant conditioning](#).

Reinforcement learning (RL) is an interdisciplinary area of [machine learning](#) and [optimal control](#) concerned with how an intelligent agent should take actions in a dynamic environment in order to *maximize a reward* signal. Reinforcement learning is one of the [three basic machine learning paradigms](#), alongside [supervised learning](#) and [unsupervised learning](#).

[Q-learning](#) at its simplest stores data in tables. This approach becomes *infeasible* as the number of states/actions increases (e.g., if the state space or action space were continuous), as the probability of the agent trying a particular state and performing a particular action diminishes.

Reinforcement learning differs from supervised learning in not needing labelled input-output pairs to be presented, and in not needing sub-optimal actions to be explicitly corrected. Instead, the focus is on finding a balance between exploration (of



The typical framing of a Reinforcement Learning (RL) scenario: an agent takes actions in an environment, which is interpreted into a reward and a state representation, which are fed back to the agent.

Appearance [hide](#)

Text

☐ Small
☒ Standard
☐ Large

Width

☒ Standard
☐ Wide

Color (beta)

☐ Automatic
☒ Light
☐ Dark

دو خط پژوهشی اخیر، مسئله را قاب بندی می کنند اما هر کدام یک شکاف باقی می گذارند:

◀ Constraint-aware policy optimization (Duan et al., 2023):

نخستین کاربرد formal safe RL در این حوزه. تنظیم نیرو را به صورت یک CMDP فرمول بندی می کند و با CPO حل می کند. اما قید نیرو یک آستانه ثابت است که در آموزش پخت شده؛ برای بیمار frail یا ناحیه بدن دیگر، باید سیاست دیگری آموزش داده شود.

◀ Online optimization for offline safe RL (O3SRL): با یک باندیت

EXP3 ضریب لاگرانژ را آنلاین انتخاب می کند. اما ضریب context-free است و نمونه زدن مستقیم آن در حلقه online، واریانس زیادی به سیگنال یادگیری تزریق می کند.

اسکن را به صورت یک CMDP مدل می‌کنیم: $(\mathcal{S}, \mathcal{A}, P, r, c, \gamma)$

◀ $s \in \mathcal{S}$ حالت، $a \in \mathcal{A}$ عمل، P هسته گذار

◀ r پاداش و $c \in \{0, 1\}$ هزینه ایمنی هر گام

هدف محدود شده:

$$\max_{\theta} J_r(\pi_{\theta}) \quad \text{s.t.} \quad \mathbb{E}[c] \leq d$$

که d نرخ مجاز نقض در هر گام است (ما $d = 0.02$ استفاده می‌کنیم).

سیاست را با PPO بهینه می‌کنیم:

$$\mathcal{L}^{\text{clip}}(\theta) = \mathbb{E}_t \left[\min(\rho_t \hat{A}_t, \text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right]$$

با $\epsilon = 0.2$.

چون پاداش وظیفه و هزینه ایمنی، سیگنال‌هایی مجزا و اغلب متضاد هستند، دو منتقد نگه می‌داریم: منتقد پاداش $V_R(s)$ و منتقد هزینه $V_C(s)$.

برای هر دو، GAE را روی رولوت‌های با طول متناهی T محاسبه می‌کنیم:

$$\delta_t^R = r_t + \gamma(1 - d_t)V_R(s_{t+1}) - V_R(s_t)$$

$$\hat{A}_t^R = \sum_{l=0}^{T-t-1} (\gamma \lambda_{\text{GAE}})^l \delta_{t+l}^R$$

که $\gamma = 0.99$ و $\lambda_{\text{GAE}} = 0.95$.

لاگرانژ CMDP برابر است با:

$$\mathcal{L}(\theta, \lambda) = J_r(\pi_\theta) - \lambda(J_c(\pi_\theta) - d), \quad \lambda \geq 0$$

در چارچوب online ما، این ریلکس دیکته می‌کند که بازیگر با یک مزیت ایمن مرکب به‌روزرسانی شود:

$$\hat{A}_t^{\text{safe}} = \hat{A}_t^R - \lambda \hat{A}_t^C$$

How λ is set and stabilized is the central algorithmic design axis studied in this work.

یک محدودیت مهم در محیط باز Hase et al. وجود دارد: آن روی یک grid-world آفلاین از تصاویر ایستا و پیش‌ضبط‌شده حرکت می‌کند.

چون تصاویر پیش‌ضبط شده‌اند، نیروی تماس در زمان جمع‌آوری داده ثابت است؛ پس برای یک عامل ممکن نیست فشار را به‌صورت پویا تغییر دهد یا فیزیک امپدانس بلادرنگ را تجربه کند.

برای مطالعه ایمنی پیوسته نیرو، تمام آزمایش‌های ما روی یک شبیه‌ساز فیزیک پویا، خودبسنده و بدون وابستگی بیرونی انجام می‌شود.

Kinematics, low-pass impedance force control,
and a B-mode speckle/bone/shadow image model — CPU only.

پاداش مرکب به صورت متراکم شکل می‌گیرد:

$$r = \underbrace{5.0 q}_{\text{quality}} + \underbrace{3.0 e^{-\frac{1}{2}(e/0.015)^2}}_{\text{centering}} - \underbrace{35.0 e^2 - 4.0 |e|}_{\text{tracking}} \\ - \underbrace{0.5 (F - F_{\text{tgt}})^2}_{\text{force budget-aware}} - \underbrace{0.15 \|a - a_{\text{prev}}\|^2}_{\text{smoothness}} - \underbrace{0.05 \|a\|^2}_{\text{effort}}$$

که هدف بودجه‌آگاه $F_{\text{tgt}} = \min(F_{\text{opt}}, \kappa - 0.4)$ نیرو را به سمت بالاترین مقدار ایمن می‌کشد.

هزینه ایمنی، یک اندیکاتور سخت از عبور از سقف اپراتور است:

$$c = \mathbf{1}[F > \kappa]$$

مشاهده ۱۰ بعدی ما به صورت زیر است:

$$s = [x, y, e, \dot{e}, F, \dot{F}, q, \boxed{\kappa}, \boxed{e^{+5}}, \boxed{e^{+15}}]$$

سه ورودی کادرشده، نوآوری‌های معماری این کار را حمل می‌کنند:

- ▶ κ سقف اپراتور است.
- ▶ e^{+5} و e^{+15} خطاهای جانبی پیش‌نگر در ۵ و ۱۵ گام آینده هستند.

در حالت ablation بدون پیش‌نگری، این دو ورودی صفر می‌شوند و معماری شبکه در بقیه موارد تغییری نمی‌کند.

به‌جای آموزش یک سیاست به‌ازای هر حد نیرو، خودِ حد را ورودی می‌کنیم.

چون κ هم در مشاهده، هم در هدف پاداش بودجه‌آگاه $F_{\text{tgt}} = \min(F_{\text{opt}}, \kappa - 0.4)$ ، و هم در هزینه ظاهر می‌شود، سیاست $\pi_{\theta}(a | s, \kappa)$ و هر دو منقد، رفتاری پیوسته را یاد می‌گیرند.

در آموزش، در ابتدای هر اپیزود یک سقف تازه $N\kappa \sim \mathcal{U}[3, 12]$ نمونه‌برداری می‌کنیم.

At deployment the clinician sets — or turns — κ freely within the trained range, and the single policy responds

zero-shot: no gradient steps, no new data.

SBL ضریب λ را در هر epoch تنظیم می‌کند: $K = 5$ بازوی گسسته $\lambda_1, \dots, \lambda_5$ به‌طور یکنواخت روی $[0, 5]$ و بردار وزن $w \in \mathbb{R}_{\geq 0}^K$.

Bandit weight update (O3SRL machinery): پس از به‌روزرسانی سیاست، بازوی نمونه‌برداری شده با مقدار Lagrangian محقق $\ell = \bar{r} - \lambda_{i_t}(\bar{c} - d)$ امتیاز می‌گیرد و سپس به‌روزرسانی exponential weights انجام می‌شود:

$$w_i \leftarrow w_i \exp(-\eta \hat{\ell}_i), \quad \eta = 0.05$$

SBL's departure is entirely in how the multiplier is *consumed* by the policy, to make it usable online.

(۱) از امید استفاده کن، نه از یک نمونه. یک باندیت naive یک بازو λ_{it} را نمونه می‌گیرد و مستقیم اعمال می‌کند. این برآورد تک‌نمونه‌ای واریانس بالایی دارد و چون در به‌روزرسانی سیاست، مزیت را ضرب می‌کند، پرش‌های آن به گرادیان بازیگر منتقل می‌شود. در عوض، ما امید دقیق را حساب می‌کنیم:

$$\bar{\lambda}_t^{\text{exp}} = \sum_i p_i \lambda_i$$

که هیچ واریانس نمونه‌گیری ندارد.

(۲) آن را فیلتر پایین‌گذر کن. سپس یک EMA با هموارسازی $\tau = 0.05$ اعمال می‌کنیم:

$$\lambda_t = (1 - \tau) \lambda_{t-1} + \tau \bar{\lambda}_t^{\text{exp}}$$

برای جداسازی اثر SBL، دو قاعده ضریب دیگر را پشت یک فلگ پیاده می‌کنیم و بقیه ثابت می‌ماند:

◀ **dual**: صعود دوگانه پروژه شده $\lambda_t = \text{clip}(\lambda_{t-1} + \eta_\lambda(\bar{c} - d), 0, \lambda_{\max})$ با $\eta_\lambda = 0.5$ (استاندارد PPO-Lagrangian).

◀ **exp3_raw**: استفاده مستقیم از بازوی نمونه‌برداری شده، $\lambda_t = \lambda_{i_t}$ (باندیت آنلاین به سبک O3SRL، بدون هموارسازی).

◀ **sbl**: امید + EMA، رابطه بالا (روش ما).

```

۱ \ Initialize actor  $\theta$ , critics  $\phi_R, \phi_C$ , state  $s_1$ , arms  $\{\lambda_i\}_{i=1}^N$ , weights  $w_i = 1$ 
۲ for iteration  $k = 1, 2, \dots$  do
۳    $\theta_{\text{old}} \leftarrow \theta$ 
۴    $(s_1, \kappa_1, a_1, r_1, c_1, \dots, s_T) = \text{rollout}(s_1, \pi_{\theta_{\text{old}}})$   $\triangleright$  Conditioned on safety window  $\kappa$ 
۵    $v_t^R = V_{\phi_R}(s_t, \kappa_t)$  and  $v_t^C = V_{\phi_C}(s_t, \kappa_t)$  for  $t = 1 \dots T$ 
۶    $(A_{1:T}^R, y_{1:T}^R) = \text{GAE}(r_{1:T}, v_{1:T}^R, \gamma, \lambda_{\text{GAE}})$   $\triangleright$  Reward advantage and returns
۷    $(A_{1:T}^C, y_{1:T}^C) = \text{GAE}(c_{1:T}, v_{1:T}^C, \gamma, \lambda_{\text{GAE}})$   $\triangleright$  Cost advantage and returns
۸ end for

```

The rollout is conditioned on the operator window κ at every step, and GAE is computed for reward and cost *independently*.

- :۱ $p_i = \frac{w_i}{\sum_{j=1}^N w_j}$ for $i = 1 \dots N$: sample arm $i_k \sim p$
- :۲ $\bar{r} = \frac{1}{T} \sum_{t=1}^T r_t$; $\bar{c} = \frac{1}{T} \sum_{t=1}^T c_t$
- :۳ $\lambda_k \leftarrow (1 - \tau)\lambda_{k-1} + \tau \sum_{i=1}^N p_i \lambda_i$ $\triangleright$ SBL multiplier (expectation + EMA)
- :۴ $A_t^{\text{safe}} = A_t^R - \lambda_k A_t^C$ for $t = 1 \dots T$ $\triangleright$ Composite safe advantage
- :۵ for $m = 1 \dots M$ do
- :۶ $\rho_t = \frac{\pi_{\theta}(\mathbf{a}_t | \mathbf{s}_t, \kappa_t)}{\pi_{\theta_{\text{old}}}(\mathbf{a}_t | \mathbf{s}_t, \kappa_t)}$
- :۷ $\mathcal{L}(\theta) = -\frac{1}{T} \sum_{t=1}^T [\min(\rho_t A_t^{\text{safe}}, \tilde{\rho}_t A_t^{\text{safe}}) + c_{\text{ent}} \mathbb{H}(\pi_{\theta})]$
- :۸ Update θ, ϕ_R, ϕ_C by gradient descent
- :۹ end for
- :۱۰ $\ell \leftarrow \bar{r} - \lambda_{i_k}(\bar{c} - d)$ $\triangleright$ Realized Lagrangian for sampled arm
- :۱۱ $w_i \leftarrow w_i \exp(-\eta \ell_i)$ for $i = 1 \dots N$ $\triangleright$ EXP3 weight update

$$\lambda_k \leftarrow (1 - \tau)\lambda_{k-1} + \tau \sum_i p_i \lambda_i \text{ Key line:}$$

— the bandit is updated from a *sample*, but the policy consumes the smoothed *expectation*.

یک کنترل‌گر reactive که فقط خطای جانبی فعلی را ببیند، روی هدف منحنی عقب می‌ماند؛ چون وقتی خطا اندازه‌گیری می‌شود، پروپ قبلاً پیش رفته است. ما یک پیش‌نمای کوتاه به سیاست می‌دهیم با افزودن e^{+5} , e^{+15} به حالت.

This is a minimal, model-based form of preview control: the spine geometry is a property of the patient anatomy, so a short look-ahead is available in practice from a pre-scan or an atlas.

شرطی سازی روی یک سقف، یک حالت شکست ظریف دارد: سیاست هیچ انگیزه‌ای برای استفاده از فضای خالی زیر سقف ندارد.

در $\kappa = 12$ نیروی آموخته در N7.97 پلتفرم می‌شود، چون هدف بودجه آگاه در بهینه آکوستیک $NF_{\text{opt}} = 7$ اشباع می‌شود؛ پس حدود N3.5 از بازه اپراتور بی‌استفاده می‌ماند.

This motivates generalizing the scalar ceiling to an operator

window $[\kappa_{\text{low}}, \kappa_{\text{high}}]$.

همه پشت یک فلگ two_sided (مدل یک طرفه بالا بدون تغییر می ماند):

۱ مشاهده یک بعد بزرگ تر می شود ($10 \rightarrow 11$) و κ_{low} را می گیرد.

۲ هزینه به بیرون از پنجره تبدیل می شود: $c = \mathbf{1}[F < \kappa_{\text{low}} \text{ or } F > \kappa_{\text{high}}]$

۳ هدف پاداش به سمت نزدیک ترین نیروی درون پنجره به بهینه آکوستیک می رود:

$$F_{\text{tgt}} = \text{clip}(F_{\text{opt}}, \kappa_{\text{low}} + 0.4, \kappa_{\text{high}} - 0.4)$$





یک سقف یک طرفه، حالت حدی $\kappa_{\text{low}} \rightarrow 0$ است.

هر دو عامل در سقف ثابت $N\kappa = 5$ ارزیابی شدند.


Violations	Quality	Max force	Mean force	Model
۹۶	۹۰.۰	۴۸.۵	۲۵.۵	Baseline (Vanilla PF)
۰	۸۰.۰	۳۷.۴	۳۲.۴	HAS-RL (ours)

پایه برای بیشینه کردن کوپلینگ آکوستیک، تا خیلی فراتر از سقف فشار می‌آورد.
HAS-RL نیروی میانگین را روی $N4.32$ نگه می‌دارد و صفر نقض ثبت می‌کند، به
قیمت کیفیت پایین‌تر.

This is the intended, honest safety–quality tradeoff.



Force vs. ceiling, cumulative violations, image quality,
and lateral tracking of the scoliotic centerline.



HAS-RL (safe force, left) vs. baseline (unconstrained, right).

نیروی بالاتر (و ناامن) کوپلینگ روشن‌تری می‌دهد — همان انگیزه‌ای که قید ایمنی باید خنثی کند.


ایمنی بدون آموزش مجدد: جاروب روی سقف‌ها


این آزمایش اصلی است. همان یک سیاست آموزش‌دیده روی $\kappa \in [3, 12]$ ، بدون هیچ آموزش بیشتر، در هفت سقف متمایز ارزیابی شد.

Quality	Viol.	Max F	Mean F	(N) κ
۱۱.۰	۰	۶۷.۱	۱۳.۱	۳
۲۶.۰	۰	۶۶.۲	۵۰.۲	۴
۴۸.۰	۰	۷۸.۳	۶۱.۳	۵
۵۸.۰	۰	۷۰.۴	۵۳.۴	۶
۷۳.۰	۰	۲۶.۶	۹۸.۵	۸
۷۶.۰	۰	۴۷.۷	۱۳.۷	۱۰
۶۶.۰	۰	۴۵.۸	۹۷.۷	۱۲

▶ نیروی آموخته یکنوا با κ افزایش می‌یابد: از N1.13 تا N،7.97 یعنی پهنای N.6.84

▶ در هر سقف، صفر نقض و صفر عبور از حد فعال.





The policy responds to an operator turning the dial

mid-scan ($9 \rightarrow 4 \rightarrow 11$ N), the force following

$\kappa(t)$ in real time and never crossing it.

با فعال و صفر کردن ورودی‌های پیش‌نگر، سه seed هر حالت، دوباره آموزش می‌دهیم:

Max lateral error	RMS lateral error	Look-ahead
0.099 ± 0.092	0.061 ± 0.060	On (ours)
0.137 ± 0.068	0.084 ± 0.048	Off

پیش‌نگری خطای جانبی RMS را ۲۸٪ کاهش می‌دهد ($0.084 \rightarrow 0.061$) و خطای بیشینه نیز ۲۸٪ کم می‌شود.


We report only the clean error reduction and do not claim a phase-lag effect, which is dominated by noise at this budget.

فقط قاعده ضریب را تغییر می دهیم، سه seed هر حالت:

λ_{std}	train_viol_std	Quality	Eval viol.	Mode
0.29 ± 0.10	16.66 ± 10.24	0.576 ± 0.138	0.0 ± 0.0	dual
1.43 ± 0.50	13.51 ± 12.76	0.492 ± 0.142	0.0 ± 0.0	exp3_raw
0.42 ± 0.02	11.99 ± 12.44	0.603 ± 0.150	0.0 ± 0.0	sbl (ours)

- هر سه حالت safe هستند؛ باندیت خام *unstable* است (انحراف ضریب حدود ۳ برابر SBL).
- SBL بهترین کیفیت تصویر را می دهد و پایدارترین آموزش را دارد.

Multiplier stability: raw bandit thrashes, SBL smooths it (seed 0)




The raw EXP3 bandit (red) thrashes between discrete arms,
dual ascent (blue) ramps slowly, and SBL (green) rises
smoothly.

یک سیاست دوطرفه واحد روی برنامه درسی پنجره آموزش دید و روی شش پنجره اپراتور ارزیابی شد:

Quality	Max F	Min F	Mean F	Window
۶۷.۰	۳۳.۳	۲۳.۳	۲۶.۳	[2.5, 4]
۷۷.۰	۰۸.۴	۰۱.۴	۰۴.۴	[3, 5]
۸۸.۰	۰۹.۵	۹۹.۴	۰۲.۵	[4, 6]
۹۹.۰	۱۷.۷	۴۱.۶	۵۰.۶	[5, 8]
۹۴.۰	۳۸.۸	۳۵.۸	۳۶.۸	[7, 10]
۷۴.۰	۲۶.۱۰	۹۰.۹	۲۲.۱۰	[9, 12]

در تمام پنجره‌ها: صفر نقض خروج از پنجره و 100% سکونت درون پنجره.



The shaded band is the operator-specified window; the contact force rises with the window and stays inside it, tracking the range a one-sided ceiling left unused.

چون پنجره دوطرفه قید را واقعاً *binding* می‌کند ($\lambda \approx 2.25$ در برابر $\lambda \approx 0.5$ در حالت یک‌طرفه)، مقایسه حالت ضریب را تکرار می‌کنیم:

Spread	λ_{std}	Quality	Mode
baseline	0.26 ± 0.09	0.677 ± 0.086	dual
stable	1.53 ± 0.15	0.594 ± 0.018	exp3_raw
reproducible	0.45 ± 0.00	0.715 ± 0.011	sbl (ours)

◀ SBL دوباره بهترین کیفیت را دارد، حالا با فاصله بیشتر (0.038 در برابر 0.027).

◀ پراکندگی کیفیت SBL فقط ± 0.011 است در برابر ± 0.086 برای dual، یعنی حدود ۸ برابر فشرده‌تر.

◀ تمام حالت‌ها صفر نقض دارند.

یک پرسش طبیعی در طراحی سیستم‌های ایمنی این است: چرا نمی‌توان یک حداکثر نیروی ثابت را روی خروجی عمل ربات hard-code کرد؟

اگر یک عامل RL استاندارد داخل یک مرز شبیه‌سازی hard-coded قرار گیرد، اهمیت بیشینه‌سازی پاداش باعث می‌شود برای کوپلینگ آکوستیک به‌طور مداوم نیروهایی بسیار فراتر از حد فرمان بدهد.

روی سخت‌افزار واقعی، این یعنی actuator saturation، حرکت‌های تکه‌تکه و توقف اضطراری.

Safe RL trains the policy to *understand* the constraint,
so the agent smooths its trajectory and holds the probe
precisely

at the limit without fighting the system.

یادگیری مستقیم قید همان چیزی است که zero-shot dynamic limits را ممکن می‌کند؛ یک حد hard-coded برای تغییر آن نیاز به توقف و برنامه‌ریزی مجدد ربات دارد.

Honest scope: what each contribution actually buys.

- ▶ نتیجه κ zero-shot قوی است و تا جایی که می‌دانیم در این حوزه novel است.
- ▶ نتیجه SBL favorable اما modest است: در طراحی پاداش ما، SBL اندکی از dual ascent جلو می‌زند و مزیت روشنش پایداری آموزش نسبت به باندیت هموارنشد است.
- ▶ شکاف کیفیت با dual درون یک انحراف معیار seed قرار دارد و ما این را صریح می‌گوییم.

- ▶ نتایج در یک شبیه‌ساز ۱ بعدی رهگیری به دست آمده‌اند، نه روی سخت‌افزار واقعی یا تصاویر US واقعی؛ مدل‌های کیفیت تصویر و نیرو proxy هستند، نه مکانیک بافت کالبره‌شده.
- ▶ Ablations از سه seed استفاده می‌کنند؛ برای آشکار کردن ناپایداری باندیت خام و کاهش خطای پیش‌نگری کافی است، اما برای فواصل اطمینان تنگ روی شکاف‌های کوچک کیفیت کافی نیست.
- ▶ هندسه ستون فقرات یک سینوس ثابت است.
- ▶ هشدار بالینی: همه آستانه‌های نیرو، پارامتر شبیه‌سازی برای ارزیابی الگوریتمی هستند و نباید به عنوان آستانه‌های ایمنی بیمار اعتبارسنجی شده تفسیر شوند.

❶ **Operator-conditioned zero-shot safety**: یک سیاست،

پیوستاری از رفتارها، که بدون آموزش مجدد به سقف اپراتور پاسخ می دهد.

❷ **Smoothed Bandit-Lagrangian**: انتقال باندیت EXP3 از

offline به online با استفاده از امید به جای نمونه و یک EMA.

❸ **Anticipatory tracking**: پیش‌نگری کوتاه، خطای جانبی را ۲۸٪ کم

می کند.

❹ **Two-sided window**: ایمنی به صورت یک پنجره آکوستیک، با صفر نقض

و بازیابی حدود N3.5 فضای خالی.

Plus an open, dependency-light synthetic US simulator

so that all results are reproducible on a CPU.

<https://github.com/mhadiniknam/HAS-RL>

Thank you
Questions?

<https://github.com/mhadiniknam/HAS-RL>